

Липецкий государственный технический университет

Институт компьютерных наук
Кафедра прикладной математики и системного анализа

Отчет по лабораторной работе № 1
по дисциплине «Интеллектуальные методы анализа данных»
на тему «Разведочный анализ данных (EDA) и визуализация»

Студент		<u>Сараев А.П.</u>
Группа <u>ПМ-24-1</u>	подпись, дата	фамилия, инициалы
Руководитель		<u>Сысоев А.С.</u>
к.т.н., доцент	подпись, дата	фамилия, инициалы
учёная степень, учёное звание		

Липецк 2026 г.

Цель работы

Освоить полный цикл разведочного анализа данных (EDA): проверку базовых предположений измерительного процесса, расчёт описательных статистик, построение и интерпретацию графиков (гистограмм, Box Plot, CDF, диаграмм рассеяния), выявление выбросов, аномалий и взаимосвязей, а также формулирование гипотез для дальнейшего моделирования.

Задачи

1. Изучить философию и цели разведочного анализа данных
2. Освоить проверку четырёх фундаментальных предположений измерительного процесса с помощью 4-Plot
3. Изучить меры центральной тенденции и меры разброса
4. Освоить построение и интерпретацию гистограмм, Box Plot, CDF и KDE
5. Изучить методы анализа взаимосвязей: диаграммы рассеяния и корреляции
6. Провести сравнительный анализ распределений по группам
7. Сформулировать гипотезы для дальнейшего моделирования

1. Выполнение лабораторной работы

1.1. Описание выбранного датасета

- Название датасета: Iris — размеры цветков ириса
- Описание: измерения размеров трёх видов растений ирисов
- Количество наблюдений: 150
- Количество признаков: 4
- Тип признаков: количественные
- Шкалы измерений: номинальная, отношений
- Наличие пропусков: 0

1.2. Методика исследования

Часть 1: Подготовка и первичный осмотр данных

1. Загрузка данных в `pandas.DataFrame`
2. Вывод размерности, типов данных, первых и последних строк
3. Проверка пропусков и дубликатов
4. Определение типа и шкалы измерений для каждого признака
5. Анализ корректности вычисления среднего для каждого признака

Часть 2: Проверка базовых предположений (4-Plot)

1. Построение Run Sequence Plot
2. Построение Lag Plot
3. Построение гистограммы
4. Построение Normal Probability Plot
5. Интерпретация каждого графика и вывод о выполнении предположений

Часть 3: Описательная статистика

1. Расчёт мер центральной тенденции: среднее, медиана, мода
2. Расчёт мер разброса: дисперсия, стандартное отклонение, IQR, MAD, размах, коэффициент вариации
3. Сравнение среднего и медианы и вывод о форме распределения

Часть 4: Визуализация распределения

1. Построение гистограмм с различным числом бинов (столбцов)
2. Построение Box Plot и обнаружение выбросов по правилу $1.5 \cdot \text{IQR}$
3. Построение CDF и нахождение процентилей
4. Построение KDE и сравнение с гистограммой

Часть 5: Анализ взаимосвязей

1. Построение диаграмм рассеяния с линией регрессии
2. Расчёт ковариации и корреляций (Пирсон)
3. Построение матрицы диаграмм рассеяния
4. Проверка влияния выбросов на корреляцию
5. Формулирование гипотез о взаимосвязях

Часть 6: Сравнительный анализ

1. Выбор категориальной и количественной переменной
2. Построение Box Plot по группам
3. Построение CDF для каждой группы
4. Сравнение медиан и разброса
5. Интерпретация различий на основе графиков

Часть 7: Итоговый отчёт и выводы

1. Описание данных и их типов
2. Результаты проверки предположений
3. Описательные статистики и их интерпретация
4. Визуализации с подписями и выводами
5. Обнаруженные аномалии, выбросы и пропуски
6. Сформулированные гипотезы для дальнейшего анализа
7. Общий вывод о применимости моделей

1.3. Данные и первичный осмотр

Таблица имеет размерность 150×5 : четыре количественных измерения в сантиметрах и категориальный признак *Species*.

```
df = pd.read_csv('Iris.csv')
df = df.drop(columns='Id')
print(df.shape)
print(df.isna().sum())
print(df[df.duplicated(keep=False)])
```

Размерность данных: (150, 5)
Первые 5 строк датасета

	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

Последние 5 строк датасета

	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
145	6.7	3.0	5.2	2.3	Iris-virginica
146	6.3	2.5	5.0	1.9	Iris-virginica
147	6.5	3.0	5.2	2.0	Iris-virginica
148	6.2	3.4	5.4	2.3	Iris-virginica
149	5.9	3.0	5.1	1.8	Iris-virginica

Типы данных:
SepalLengthCm float64
SepalWidthCm float64
PetalLengthCm float64
PetalWidthCm float64
Species str
dtype: object

Рисунок 1 – Вывод датасета

Количество пропущенных значений по столбцам:
SepalLengthCm 0
SepalWidthCm 0
PetalLengthCm 0
PetalWidthCm 0
Species 0
dtype: int64
Дубликаты:

	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
9	4.9	3.1	1.5	0.1	Iris-setosa
34	4.9	3.1	1.5	0.1	Iris-setosa
37	4.9	3.1	1.5	0.1	Iris-setosa
101	5.8	2.7	5.1	1.9	Iris-virginica
142	5.8	2.7	5.1	1.9	Iris-virginica

Столбец	Тип	Шкала	Корректность среднего
SepalLengthCm	Количественные	Шкала отношений	+
SepalWidthCm	Количественные	Шкала отношений	+
PetalLengthCm	Количественные	Шкала отношений	+
PetalWidthCm	Количественные	Шкала отношений	+
Species	Категориальные	Номинальная	-

Рисунок 2 – Пропуски, дубликаты, типы, шкалы

Таблица 1. Типы признаков и шкалы измерений

Признак	Тип	Шкала	Среднее
SepalLengthCm	количественный	отношений	да
SepalWidthCm	количественный	отношений	да
PetalLengthCm	количественный	отношений	да
PetalWidthCm	количественный	отношений	да
Species	категориальный	номинальная	нет

1.4. Проверка базовых предположений: 4-Plot

Для каждого из четырёх измерений построены Run Sequence Plot, Lag Plot, гистограмма и Normal Probability Plot. Рисунки 3–6 показывают все признаки в одинаковой последовательности строк. Порядок строк соответствует группировке по видам, а не времени измерения.




Рисунок 3 – Run Sequence Plot четырёх размеров цветка




Рисунок 4 – Lag Plot: соседние записи в исходном порядке




Рисунок 5 – Гистограммы для проверки формы общего распределения




Рисунок 6 – Normal Probability Plot для четырёх размеров

Таблица 2. Интерпретация четырёх графиков

Предположение	График	Вывод
Случайный порядок	Lag Plot	Соседние записи связаны из-за расположения цветов одного вида подряд.
Постоянное положение	Run Sequence Plot	Уровень меняется около границ групп видов, особенно для размеров лепестка.
Постоянный разброс	Run Sequence Plot	Явного плавного роста разброса нет, но внутри видов он различается.
Единая форма распределения	Гистограмма и Q-Q Plot	Общая выборка неоднородна; распределение всех видов вместе отклоняется от нормального.

Таким образом, проверять нормальность и устойчивость уровня без учёта Species некорректно. Видимые скачки связаны со способом сортировки таблицы; они не означают изменение размеров цветков во времени.

1.5. Описательная статистика

В таблице 3 представлены основные меры центра и разброса, рассчитанные по всем 150 строкам. $IQR = Q_3 - Q_1$; MAD — медиана абсолютных отклонений от медианы. Дисперсии длины и ширины чашелистика равны 0,686 и 0,188, лепестка — 3,113 и 0,582 см² соответственно.

Таблица 3. Описательные статистики размеров, см

Признак	Среднее	Медиана	Мода	Ст. откл.	IQR	MAD	Размах
SepalLengthCm	5,843	5,80	5,0	0,828	1,3	0,70	3,6
SepalWidthCm	3,054	3,00	3,0	0,434	0,5	0,25	2,4
PetalLengthCm	3,759	4,35	1,5	1,764	3,5	1,25	5,9
PetalWidthCm	1,199	1,30	0,2	0,763	1,5	0,70	2,4

Среднее и медиана размеров чашелистика близки. Для длины лепестка среднее 3,759 см заметно ниже медианы 4,35 см, а мода 1,5 см соответствует группе цветков с короткими лепестками. Коэффициент вариации у ширины лепестка составляет 63,7%, у длины — 46,9%; это значительно больше, чем примерно 14,2% для обоих размеров чашелистика. Одно среднее для объединённой выборки скрывает различия между видами.

1.6. Распределения и выбросы

Гистограммы на рисунке 7 построены с 10 и 20 интервалами. При большем числе столбиков видны дополнительные детали, но общая неоднородность размеров лепестка остаётся. На рисунке 8 показаны медианы, квартили и точки за усами Box Plot.




Рисунок 7 – Гистограммы с различным числом интервалов




Рисунок 8 – Box Plot четырёх количественных признаков

По правилу $[Q_1 - 1,5IQR; Q_3 + 1,5IQR]$ за границами оказались четыре измерения ширины чашелистика. Для остальных трёх признаков глобальное правило не выделило выбросов. Эти четыре цветка — кандидаты для проверки, а не доказанные ошибки. Удаление их без изучения вида и исходных измерений могло бы исказить сравнение групп.

Эмпирическая функция распределения на рисунке 9 показывает долю наблюдений не выше выбранного значения. Ключевые процентиля приведены в таблице 4. Например, медианная длина лепестка равна 4,35 см, а 90-й процентиль — 5,80 см.




Рисунок 9 – Эмпирические функции распределения размеров

Таблица 4. Процентили размеров цветка, см

Процентиль	SepalLength	SepalWidth	PetalLength	PetalWidth
10%	4,8	2,50	1,40	0,2
25%	5,1	2,80	1,60	0,3
50%	5,8	3,00	4,35	1,3
75%	6,4	3,30	5,10	1,8
90%	6,9	3,61	5,80	2,2

KDE на рисунке 10 сглаживает гистограммы, переведённые в шкалу плотности. Для размеров лепестка видны отдельные области высокой плотности. Это согласуется с тем, что в общей таблице смешаны три вида; сглаженная кривая не заменяет сравнение распределений внутри каждого вида.




Рисунок 10 – Гистограммы плотности и оценки KDE

1.7. Связи между признаками

На рисунке 11 показаны диаграммы рассеяния с прямыми регрессии для пар размеров. Матрица рассеяния (рисунок 12) даёт общий обзор, а тепловая карта (рисунок 13) показывает коэффициенты Пирсона. Ковариация длины и ширины лепестка равна $1,296 \text{ см}^2$; её знак положителен, но величина зависит от единиц измерения. Для сравнения силы линейных связей удобнее безразмерная корреляция.




Рисунок 11 – Диаграммы рассеяния с линиями регрессии




Рисунок 12 – Матрица диаграмм рассеяния по четырём размерам




Рисунок 13 – Матрица корреляций Пирсона

Таблица 5. Некоторые коэффициенты корреляции Пирсона

Пара признаков	r
Длина и ширина лепестка	0,963
Длина чашелистика и длина лепестка	0,872
Длина чашелистика и ширина лепестка	0,818
Ширина чашелистика и длина лепестка	−0,421

Самая сильная положительная линейная связь наблюдается у длины и ширины лепестка. Для проверки влияния крайних наблюдений в ноутбуке сначала удалены две лишние копии строк, затем повторно рассчитаны шесть пар корреляций после исключения точек за границами $1,5IQR$. Такое сопоставление показывает чувствительность коэффициента к небольшому числу наблюдений. Общая корреляция может также отражать различия между видами, поэтому для дальнейшего анализа следует вычислить её внутри каждой группы *Species*.

1.8. Сравнение трёх видов ириса

Категориальная переменная *Species* задаёт группы; количественными переменными служат четыре размера цветка. Групповые Box Plot на рисунке 14 и CDF на рисунке 15 позволяют сравнить положения и разброс распределений. Для длины лепестка численные результаты даны в таблице 6.




Рисунок 14 – Размеры чашелистика и лепестка по видам: Box Plot




Рисунок 15 – CDF четырёх размеров отдельно для каждого вида

Таблица 6. Длина лепестка по видам, см

Вид	Среднее	Медиана	Ст. откл.	IQR
Iris-setosa	1,464	1,50	0,174	0,175
Iris-versicolor	4,260	4,35	0,470	0,600
Iris-virginica	5,552	5,55	0,552	0,775

У *Iris-setosa* лепестки короче всего, а их длина изменяется меньше. Медиана последовательно возрастает от 1,50 до 4,35 и 5,55 см. На CDF это соответствует сдвигу кривых вправо. Размеры чашелистика разделяют виды слабее, а значения *versicolor* и *virginica* частично перекрываются. Наблюдения позволяют выдвинуть гипотезы: размеры лепестка будут особенно полезны для определения вида; связь длины и ширины лепестка сохранится внутри групп, но её сила может различаться у трёх видов. Эти гипотезы требуют отдельной проверки, а корреляция сама по себе не доказывает причинность.

Заключение

В лабораторной работе изучены 150 наблюдений набора Iris: четыре количественных размера цветка и номинальный признак вида. После исключения служебного номера записи формальных пропусков нет. В группах повторов находятся пять строк, из которых две являются лишними копиями. По правилу $1,5IQR$ четыре значения ширины чашелистика отмечены как кандидаты на выбросы; автоматически считать их ошибками нельзя.

Графики 4-Plot показывают влияние порядка строк: наблюдения сгруппированы по видам. Объединённые распределения, особенно у размеров лепестка, неоднородны и отклоняются от нормального закона. Среднее и медиана длины лепестка различаются, поэтому при описании типичного цветка важно учитывать вид. Самая сильная корреляция Пирсона в общей выборке наблюдается у длины и ширины лепестка: $r \approx 0,963$.

Групповые Box Plot, CDF и описательные статистики показывают, что длина лепестка наиболее заметно различается у трёх видов: медианы составляют 1,50, 4,35 и 5,55 см для *setosa*, *versicolor* и *virginica*. Для дальнейшего исследования можно проверить модель определения вида по размерам цветка, уделив особое внимание лепестку. Перед моделированием следует оценить связи и распределения отдельно внутри каждого вида и проверить качество на отложенной выборке. Выводы не следует переносить без проверки на произвольные популяции ирисов.