

Разведочный анализ данных (EDA)

Содержание:

- Введение: философия EDA и ее место в анализе данных
- Цели и задачи EDA
- EDA против классического подхода
- EDA против суммарной статистики
- Роль графики в EDA
- Типы данных и шкалы измерений
- Категории задач EDA
- Типы переменных
- Практический пример: данные NSFG
- Базовые предположения измерительного процесса
- Четыре фундаментальных предположения
- Почему проверка предположений критически важна
- Последствия нарушения предположений
- Техники проверки предположений: 4-Plot
- Описательная статистика: меры центральной тенденции
- Описательная статистика: меры разброса
- Меры формы распределения: асимметрия и эксцесс
- Гистограммы: теория, построение и интерпретация
- Ящик с усами (Box Plot)
- Кумулятивные функции распределения (CDF)
- Функции плотности вероятности (PDF) и KDE
- Анализ взаимосвязей: диаграммы рассеяния
- Корреляция: теория, ковариация, Пирсон, Спирмен
- Практический EDA: пошаговый процесс

Содержание

1	Введение в разведочный анализ данных	4
1.1	Что такое EDA?	4
1.2	Исторический контекст и развитие EDA	4
1.3	Семь целей EDA	5
1.4	Дополнительные цели EDA в современной практике	7
1.5	EDA против классического подхода	7
1.6	Философские основания EDA	8
1.7	EDA против суммарной статистики	9
1.8	Роль графики в EDA	9
1.9	Квартет Анскомба: классический пример	10
1.10	Современные инструменты EDA	11
2	Типы данных и шкалы измерений	11
2.1	Категории задач EDA	11
2.2	Подробное описание категорий задач	12
2.2.1	Унарный анализ	12
2.2.2	Анализ контроля	12
2.2.3	Сравнительный анализ	12
2.2.4	Скрининг	13
2.2.5	Оптимизация	13
2.2.6	Регрессия	13
2.2.7	Анализ временных рядов	13
2.2.8	Многомерный анализ	13
2.3	Типы переменных	14
2.4	Шкалы измерений	14
2.5	Практический пример: данные NSFG	15
2.6	Особенности кросс-секционных данных	15
2.7	Другие типы исследований	16
3	Базовые предположения измерительного процесса	16
3.1	Четыре фундаментальных предположения	16
3.2	Подробное описание каждого предположения	17
3.2.1	Случайность	17
3.2.2	Фиксированное распределение	17
3.2.3	Фиксированное положение	18
3.2.4	Фиксированная вариация	18
3.3	Почему проверка предположений критически важна	18
3.4	Последствия нарушения предположений	19
3.4.1	Нарушение случайности	19

3.4.2	Нарушение фиксированного положения	19
3.4.3	Нарушение фиксированной вариации	20
3.4.4	Нарушение распределения	20
3.5	Техники проверки предположений: 4-Plot	20
3.6	Дополнительные инструменты проверки предположений	21
4	Описательная статистика	21
4.1	Меры центральной тенденции (Location)	22
4.1.1	Среднее арифметическое (Mean)	22
4.1.2	Медиана (Median)	22
4.1.3	Мода (Mode)	23
4.1.4	Midrange	24
4.2	Меры разброса (Scale)	24
4.2.1	Дисперсия (Variance)	24
4.2.2	Стандартное отклонение (Standard Deviation)	25
4.2.3	Интерквартильный размах (IQR)	25
4.2.4	Другие меры разброса	25
4.3	Меры формы распределения	26
4.3.1	Асимметрия (Skewness)	26
4.3.2	Экссесс (Kurtosis)	27
4.4	Пятичисловая сводка	28
4.5	Сравнение мер центральной тенденции и разброса	28
5	Гистограммы: построение и интерпретация	28
5.1	Определение и математическое обоснование	28
5.2	Влияние ширины интервала	29
5.3	Детальная интерпретация гистограмм	29
5.3.1	Нормальное распределение (симметричное, умеренные хвосты) . .	30
5.3.2	Симметричное, короткие хвосты	30
5.3.3	Симметричное, длинные хвосты	30
5.3.4	Бимодальное распределение	30
5.3.5	Асимметрия вправо	31
5.3.6	Асимметрия влево	31
5.4	Выбросы и их обнаружение	31
5.5	Преобразования данных	31
6	Ящик с усами (Box Plot)	32
6.1	Определение и построение	32
6.2	Использование Box Plot для сравнения распределений	32
6.3	Модификации Box Plot	33

7	Кумулятивные функции распределения (CDF)	33
7.1	Определение и свойства	33
7.2	Преимущества CDF перед PMF	34
7.3	Процентили и квантили	34
7.4	Сравнение распределений с помощью CDF	35
7.5	Эмпирическая CDF	35
7.6	Генерация случайных чисел из CDF	35
8	Функции плотности вероятности (PDF) и KDE	35
8.1	PDF как производная CDF	35
8.2	Нормальное распределение	36
8.3	Другие важные распределения	37
8.4	Оценка плотности ядром (KDE)	37
8.5	Сравнение KDE и гистограммы	38
9	Анализ взаимосвязей	38
9.1	Диаграммы рассеяния	38
9.2	Корреляция	38
9.2.1	Коварияция	38
9.2.2	Корреляция Пирсона	39
9.2.3	Корреляция Спирмена	39
9.2.4	Корреляция Кендалла	40
9.3	Корреляция и причинность	40
9.4	Матрица диаграмм рассеяния	41
10	Практический EDA: пошаговый процесс	41
10.1	1. Импорт и очистка данных	41
10.2	2. Исследование одной переменной	41
10.3	3. Парные исследования	42
10.4	4. Многомерный анализ	42
10.5	5. Оценка и проверка гипотез	42
10.6	6. Визуализация	42
10.7	7. Документирование	42
10.8	8. Итеративность процесса	42

1 Введение в разведочный анализ данных

1.1 Что такое EDA?

Разведочный анализ данных (Exploratory Data Analysis, EDA) представляет собой фундаментальный подход к анализу данных, который был впервые систематически описан Джоном Тьюки (John W. Tukey) в его классической работе 1977 года. Как отмечает NIST Handbook, EDA — это «подход/философия анализа данных, которая использует различные (преимущественно графические) техники» для достижения глубокого понимания структуры данных.

Ключевая идея EDA заключается в том, что анализ данных должен начинаться с исследования, а не с подтверждения гипотез. Вместо того чтобы спрашивать «подтверждают ли данные мою модель?», EDA спрашивает «что данные могут мне рассказать?». Этот сдвиг в мышлении имеет глубокие последствия для практики анализа данных.

Allen B. Downey в книге *Think Stats* формулирует это так: **«Тезис этой книги в том, что данные в сочетании с практическими методами могут отвечать на вопросы и направлять решения в условиях неопределенности»**. EDA — это первый и самый важный шаг на этом пути.

Определение 1.1. *Разведочный анализ данных (EDA) — это подход к анализу данных, который использует преимущественно графические методы для максимализации инсайта, выявления структуры, обнаружения выбросов и проверки предположений, предшествуя формальному моделированию. EDA основан на принципе, что данные должны «говорить сами за себя», а не подгоняться под заранее заданную модель.*

Исторически EDA берет начало в работах Джона Тьюки, который в 1977 году опубликовал фундаментальную работу *Exploratory Data Analysis*. Тьюки предложил радикально новый подход к статистике: вместо того чтобы навязывать данным модели, следует сначала исследовать данные, понять их структуру, и только затем выбирать подходящие методы анализа. Этот подход стал революционным, поскольку до этого статистика в основном занималась подтверждением гипотез (confirmatory data analysis), а не их генерацией.

Ключевое отличие EDA от классического анализа:

Классический: Проблема → Данные → Модель → Анализ → Выводы

EDA: Проблема → Данные → Анализ → Модель → Выводы

1.2 Исторический контекст и развитие EDA

Чтобы глубже понять философию EDA, полезно рассмотреть исторический контекст. До 1970-х годов статистика в основном развивалась в рамках так называемого **подтверждающего анализа данных** (Confirmatory Data Analysis, CDA). В этом подходе

исследователь сначала формулирует гипотезу, затем собирает данные и применяет статистический тест, чтобы принять или отклонить гипотезу. Такой подход хорошо работал в контролируемых экспериментах, но плохо подходил для анализа больших и сложных наборов данных, которые стали появляться в науке, промышленности и бизнесе.

Джон Тьюки, работавший в Bell Labs и Принстонском университете, столкнулся с необходимостью анализировать данные, которые не укладывались в прокрустово ложе классических статистических моделей. Он предложил рассматривать анализ данных как **отдельную дисциплину**, а не просто как приложение математической статистики. В своей книге 1977 года Тьюки писал: «Разведочный анализ данных — это отношение, это гибкость, это поиск. Это не набор техник, хотя техники и важны».

Тьюки ввел множество понятий и инструментов, которые сегодня являются стандартными в EDA:

- **Пятичисловая сводка** (минимум, первый квартиль, медиана, третий квартиль, максимум).
- **Ящик с усами** (Box Plot) — графическое представление пятичисловой сводки.
- **Стебель-лист** (Stem-and-Leaf Plot) — способ визуализации распределения без потери данных.
- **Устойчивые (робастные) статистики** — медиана, IQR, MAD, которые мало чувствительны к выбросам.
- **Преобразования данных** — логарифмическое, квадратичное, Box-Cox для стабилизации вариации и нормализации.

С тех пор EDA развивался параллельно с развитием вычислительной техники. Появление персональных компьютеров и таких языков, как S, R, Python, сделало графические методы доступными каждому аналитику. Современные библиотеки (matplotlib, seaborn, ggplot2, plotly) позволяют строить сложные интерактивные визуализации за считанные секунды.

1.3 Семь целей EDA

Согласно NIST Handbook, EDA преследует семь конкретных целей, каждая из которых важна для полноценного понимания данных.

1. **Максимизация инсайта** в структуру данных. Инсайт означает обнаружение и раскрытие скрытой структуры данных. Это «чувство» данных, которое приходит только через графические методы. Как подчеркивают авторы NIST Handbook: «Инсайт подразумевает обнаружение и раскрытие скрытой структуры в данных». Причем эта структура может быть гораздо богаче и сложнее, чем просто список числовых характеристик. Настоящий инсайт приходит только через призму графических методов, и никакие количественные оценки не могут его заменить.

2. **Выявление лежащей в основе структуры** данных. Данные редко бывают просто набором случайных чисел. За ними часто стоит определенная структура: зависимости между переменными, группировки объектов, периодические колебания. Например, данные могут содержать сезонные компоненты, циклические паттерны или скрытые кластеры объектов. Выявление этой структуры — первый шаг к построению адекватной модели.
3. **Извлечение важных переменных.** В реальных задачах у нас часто есть множество потенциальных факторов, влияющих на результат. EDA позволяет быстро определить, какие из этих факторов действительно важны, а какие можно исключить из дальнейшего рассмотрения. Это критически важно, особенно когда мы имеем дело с высокоразмерными данными, где число переменных может измеряться сотнями или тысячами.
4. **Обнаружение выбросов и аномалий.** Выбросы — это точки данных, которые сильно отличаются от основной массы. Они могут быть результатом ошибок измерения, сбоев оборудования или, наоборот, указывать на важные, но редкие события. Downey отмечает: «Выбросы часто являются "нашими друзьями поскольку они пытаются сообщить нам нечто важное о процессе». Классический пример — обнаружение озоновой дыры над Антарктидой, где автоматические алгоритмы отбрасывали «выбросы» — низкие значения озона, что откладывало открытие на годы.
5. **Проверка базовых предположений.** Многие классические статистические методы основаны на предположениях о том, как устроены данные: например, что данные распределены нормально, что они независимы, что их вариация постоянна. Если эти предположения не выполняются, результаты анализа могут быть неверными. EDA позволяет проверить эти предположения до того, как мы начнем применять какие-либо статистические тесты.
6. **Разработка «экономных» (парсимониальных) моделей.** Парсимония — это принцип, согласно которому из двух моделей, одинаково хорошо описывающих данные, следует выбирать более простую. EDA помогает понять, какая модель будет адекватной, но при этом достаточно простой для интерпретации и использования. Принцип бритвы Оккама гласит: «Не следует множить сущности без необходимости». В статистике это означает, что модель с меньшим числом параметров предпочтительнее, если она объясняет данные не хуже сложной.
7. **Определение оптимальных настроек факторов.** Во многих инженерных и научных задачах мы хотим не просто понять данные, но и найти наилучшие значения параметров, чтобы добиться желаемого результата. EDA помогает в этом, показывая, как изменение факторов влияет на отклик. Например, в промышленном эксперименте мы можем варьировать температуру, давление и концентрацию

реагента, чтобы максимизировать выход продукта. EDA помогает визуализировать поверхность отклика и найти оптимум.

1.4 Дополнительные цели EDA в современной практике

Помимо семи классических целей, сформулированных в NIST Handbook, современная практика EDA включает ещё несколько важных задач:

- **Оценка качества данных.** EDA позволяет выявить пропущенные значения, дубликаты, противоречия, некорректные типы данных. Это критически важно, поскольку «мусор на входе — мусор на выходе» (garbage in, garbage out).
- **Понимание предметной области.** Графики и сводки помогают аналитику погрузиться в предметную область, понять единицы измерения, диапазоны допустимых значений, семантику переменных.
- **Формулирование гипотез.** EDA — это генератор гипотез. Увидев закономерность на графике, аналитик формулирует гипотезу, которую затем можно проверить формальными методами.
- **Подготовка к машинному обучению.** EDA помогает выбрать признаки, преобразовать переменные, обнаружить утечки данных (data leakage) и оценить сложность задачи.
- **Коммуникация с заказчиком.** Визуализации, созданные в ходе EDA, часто становятся основой для отчётов и презентаций, помогая донести результаты до людей без статистического образования.

1.5 EDA против классического подхода

Сравнение EDA с классическим (подтверждающим) анализом данных раскрывает фундаментальные различия в методологии. Традиционный подход, который доминировал в статистике на протяжении десятилетий, следует строгой последовательности. Сначала исследователь формулирует проблему, затем собирает данные. После этого он выбирает модель — например, линейную регрессию или дисперсионный анализ. И только затем проводится анализ для оценки параметров этой модели и формулируются выводы.

EDA предлагает радикально иную последовательность. Вместо того чтобы навязывать модель данным, EDA предлагает сначала проанализировать данные, понять их структуру и только затем выбрать модель.

Различия между подходами проявляются по шести ключевым аспектам, которые подробно представлены в таблице 1.

Таблица 1: Детальное сравнение классического подхода и EDA

Критерий	Классический подход	EDA
Модель	Навязывает модели (детерминированные и вероятностные) данным. Анализ зависит от правильности выбора модели.	Позволяет данным предложить адекватные модели. Модель выбирается на основе анализа.
Фокус	На модели: оценка параметров, проверка гипотез, прогнозные значения.	На данных: структура, выбросы, закономерности, модели, предложенные данными.
Техники	Преимущественно количественные: ANOVA, t-тесты, F-тесты, критерии хи-квадрат, доверительные интервалы.	Преимущественно графические: диаграммы рассеяния, box plots, гистограммы, вероятностные графики.
Строгость	Строгие, формальные, «объективные». Результаты выражаются в p-значениях и доверительных интервалах.	Субъективные, зависят от интерпретации, но очень наводящие и глубокие. Опытные аналитики обычно приходят к одинаковым выводам.
Обработка	Сжимает все данные в несколько чисел («фильтрация»). Это дает фокус, но приводит к потере информации.	Использует и показывает все доступные данные. Нет потери информации через фильтрацию.
Предположения	Зависит от строгих предположений (нормальность, независимость, гомоскедастичность). Нарушение предположений делает результаты невалидными.	Делает мало предположений или не делает их вовсе. Показывает данные «как есть», с минимальными допущениями.

1.6 Философские основания EDA

За различиями в методологии стоят глубокие философские различия. Классический подход основан на **гипотетико-дедуктивной модели** науки: учёный выдвигает гипотезу, выводит из неё проверяемые следствия и проверяет их на данных. EDA ближе к **индуктивной модели**: учёный начинает с наблюдений и постепенно строит обобщения.

Тьюки настаивал на том, что анализ данных — это не просто применение готовых формул, а **творческий процесс**. Он сравнивал аналитика с детективом, который исследует место преступления: нужно собрать улики, посмотреть на них с разных сторон, построить несколько версий и только потом выбрать наиболее правдоподобную.

В современной науке о данных EDA стал стандартной первой фазой любого проекта. Даже если конечная цель — построение сложной модели машинного обучения, EDA позволяет:

- Понять, какие данные есть в наличии и в каком они состоянии.
- Выявить очевидные проблемы (пропуски, выбросы, дубликаты).
- Сформулировать гипотезы о связях между переменными.
- Выбрать признаки для модели.
- Оценить, какие модели могут быть применимы.

1.7 EDA против суммарной статистики

Иногда путают EDA с простым вычислением суммарных статистик — среднего, стандартного отклонения, минимального и максимального значений. Однако между этими подходами есть принципиальная разница.

Суммарная статистика — это пассивное, историческое описание данных. Ее цель — просто свести большой массив чисел к нескольким ключевым показателям. Она отвечает на вопрос «как выглядят данные в среднем?», но не помогает понять, почему они выглядят именно так.

EDA — это активный, ориентированный на будущее подход. Вместо того чтобы просто описывать данные, EDA использует их как «окно» для понимания процесса, который их породил. Цель EDA — не просто констатировать факты, а понять процесс и улучшить его в будущем. Если суммарная статистика — это фотография, то EDA — это видео, которое показывает динамику и структуру.

Приведём наглядный пример. Предположим, у нас есть данные о температуре воздуха за год в двух городах. Средняя температура в обоих городах может быть одинаковой, например $+10^{\circ}\text{C}$. Но если в одном городе климат мягкий и температура колеблется от 0°C до $+20^{\circ}\text{C}$, а в другом — резко континентальный и температура колеблется от -30°C до $+30^{\circ}\text{C}$, то суммарная статистика (среднее) не покажет этого различия. EDA же с помощью графика временного ряда, гистограммы и ящика с усами сразу выявит разницу в разбросе и форме распределения.

1.8 Роль графики в EDA

В EDA графика играет ключевую, незаменимую роль. Это не случайность — это следствие того, как устроен человеческий мозг. Наша зрительная система невероятно эффективно обрабатывает визуальную информацию, распознавая паттерны, аномалии и структуры мгновенно, часто без осознанных усилий.


Авторы NIST Handbook подчеркивают это с особой силой: *«Если вы не используете статистическую графику, вы жертвуете инсайтом в один или несколько аспектов структуры данных»*. И далее: *«Графические инструменты — это кратчайший путь к получению инсайта в данные»*.

Графика в EDA выполняет несколько критических функций:

1. **Визуализация структуры данных.** Графики позволяют увидеть кластеры, тренды, циклы, сезонность и другие паттерны, которые могут быть совершенно неочевидны в таблицах чисел.
2. **Проверка предположений.** На графике легко заметить, нарушается ли предположение о нормальности (по форме гистограммы или вероятностного графика), о постоянстве вариации (по графику последовательности) или о случайности (по графику с лагом).

3. **Выбор модели.** По форме облака точек на диаграмме рассеяния можно понять, подходит ли линейная модель или нужна нелинейная (квадратичная, экспоненциальная, синусоидальная).
4. **Обнаружение выбросов.** На графике выбросы видны сразу. В некоторых случаях (например, на графике с лагом) они могут быть видны даже тогда, когда на других графиках незаметны.
5. **Идентификация взаимосвязей.** График рассеяния или матрица диаграмм рассеяния позволяют увидеть взаимосвязи между переменными.
6. **Коммуникация результатов.** Графики — лучший способ донести результаты анализа до заинтересованных сторон, включая тех, кто не имеет статистического образования.

Пример Anscombe: важность визуализации



Пример Anscombe: Четыре разных набора данных дают одинаковые статистические характеристики (среднее $X = 9$, среднее $Y = 7.5$, корреляция $= 0.816$), но совершенно разные графики. Это демонстрирует, почему визуализация критически важна.

1.9 Квартет Ансcombe: классический пример

Квартет Ансcombe — это четыре набора данных, которые имеют практически одинаковые статистические характеристики, но совершенно разные графики. Этот пример был предложен Фрэнсисом Ансcombe в 1973 году для демонстрации важности визуализации данных.

Все четыре набора данных имеют:

- Среднее значение X : 9.0
- Среднее значение Y : 7.5
- Дисперсию X : 11.0
- Дисперсию Y : 4.12

- Корреляцию: 0.816
- Линию регрессии: $y = 3 + 0.5x$

Однако при построении графиков выясняется:

1. Первый набор — классическая линейная зависимость с небольшим разбросом.
2. Второй набор — явная нелинейная (квадратичная) зависимость.
3. Третий набор — идеальная линейная зависимость с одним выбросом.
4. Четвертый набор — все точки X равны 8, кроме одной, которая определяет наклон линии.

Этот пример учит нас, что **суммарные статистики могут быть обманчивы**. Только визуализация может выявить истинную структуру данных.

1.10 Современные инструменты EDA

В современной практике EDA используется широкий спектр инструментов:

- **Python:** библиотеки pandas (манипуляция данными), matplotlib (базовая графика), seaborn (статистическая графика), plotly (интерактивная графика), scipy (статистические тесты), statsmodels (регрессия и диагностика).
- **R:** базовые графические функции, ggplot2 (грамматика графики), dplyr (манипуляция данными), tidyverse (экосистема пакетов).
- **Специализированные инструменты:** Tableau, Power BI, Datawrapper, Observable.
- **Jupyter Notebooks:** интерактивная среда, позволяющая сочетать код, графики и текст.

2 Типы данных и шкалы измерений

2.1 Категории задач EDA

NIST Handbook классифицирует задачи EDA по типу данных и целям анализа. Понимание этой классификации помогает выбрать правильные инструменты для каждой конкретной задачи.

Тип задачи	Данные	Техники
Унарный	Один столбец Y	4-Plot, Probability Plot, PPCC Plot
Контроль	Один столбец Y	Контрольные карты
Сравнительный	Y + несколько факторов	Block Plot, Scatter Plot, Box Plot

Тип задачи	Данные	Техники
Скрининг	Y + много факторов $X_1, \dots, X_k$	Block Plot, Bihistogram
Оптимизация	Y + много факторов	Contour Plot, Least Squares
Регрессия	Y + непрерывные факторы	Scatter Plot, 6-Plot
Временные ряды	Y_t (зависит от времени)	Autocorrelation Plot, Spectral Plot
Многомерный	$X_1, \dots, X_k$ (без Y)	Star Plot, Scatter Plot Matrix

2.2 Подробное описание категорий задач

Рассмотрим каждую категорию задач EDA более подробно.

2.2.1 Унарный анализ

Унарный анализ имеет дело с одной переменной Y . Цель — понять распределение этой переменной, выявить выбросы, проверить предположения. Основные инструменты:

- **4-Plot:** комбинация четырёх графиков (Run Sequence Plot, Lag Plot, Histogram, Normal Probability Plot).
- **Probability Plot:** график упорядоченных значений против теоретических квантилей.
- **PPCC Plot:** график вероятностного коэффициента корреляции для выбора параметров распределения.

2.2.2 Анализ контроля

Анализ контроля используется в статистическом управлении процессами (SPC). Цель — определить, находится ли процесс в статистически контролируемом состоянии. Основным инструментом — контрольные карты (X-bar, R, S, EWMA, CUSUM).

2.2.3 Сравнительный анализ

Сравнительный анализ используется, когда есть одна откликовая переменная Y и несколько факторов (группирующих переменных). Цель — сравнить распределения Y для разных уровней факторов. Инструменты:

- **Box Plot:** сравнение медиан и разброса по группам.
- **Block Plot:** график, показывающий значения Y для каждой комбинации факторов.
- **Scatter Plot:** если факторы непрерывные.

2.2.4 Скрининг

Скрининг используется, когда есть много потенциальных факторов $X_1, \dots, X_k$ и нужно выявить наиболее важные. Инструменты:

- **Block Plot:** позволяет визуально оценить эффект каждого фактора.
- **Bihistogram:** сравнение двух гистограмм (например, для двух уровней фактора).

2.2.5 Оптимизация

Оптимизация используется, когда нужно найти значения факторов, максимизирующие или минимизирующие отклик Y . Инструменты:

- **Contour Plot:** линии уровня отклика в пространстве двух факторов.
- **Least Squares:** метод наименьших квадратов для подгонки поверхности отклика.

2.2.6 Регрессия

Регрессионный анализ используется для моделирования зависимости Y от непрерывных факторов. Инструменты:

- **Scatter Plot:** визуализация зависимости.
- **6-Plot:** диагностика регрессионной модели (остатки против предсказанных значений, QQ-plot остатков и т.д.).

2.2.7 Анализ временных рядов

Анализ временных рядов используется, когда данные упорядочены во времени. Цель — выявить тренд, сезонность, циклы, автокорреляцию. Инструменты:

- **Autocorrelation Plot:** график автокорреляционной функции.
- **Spectral Plot:** спектральная плотность мощности.

2.2.8 Многомерный анализ

Многомерный анализ используется, когда нет откликовой переменной, а есть только набор признаков $X_1, \dots, X_k$. Цель — выявить структуру данных: кластеры, выбросы, корреляции. Инструменты:

- **Star Plot:** многомерная визуализация в виде звезды.
- **Scatter Plot Matrix:** матрица диаграмм рассеяния для всех пар переменных.

2.3 Типы переменных

В EDA данные классифицируются по типам переменных. Корректное определение типа переменной критически важно для выбора методов анализа и предобработки.

- **Количественные (непрерывные):** принимают значения на некотором интервале. *Примеры:* температура, вес, рост. Такие переменные можно складывать, вычитать, умножать и делить.
- **Дискретные (целочисленные):** принимают только целые значения. *Примеры:* количество детей, число посещений. Они могут принимать только определенные значения, но между ними можно выполнять арифметические операции.
- **Категориальные:**
 - *Номинальные:* значения не имеют порядка. *Примеры:* цвет, страна, пол. Для таких переменных не имеет смысла говорить «больше» или «меньше».
 - *Порядковые:* значения имеют порядок, но расстояния между ними не определены. *Примеры:* уровень образования, оценка удовлетворенности. Мы знаем, что бакалавр выше школы, но не можем сказать, на сколько.

2.4 Шкалы измерений

Более формально типы переменных описываются через **шкалы измерений**, введенные психологом Стэнли Смитом Стивенсом в 1946 году. Выделяют четыре шкалы:

1. **Номинальная шкала** (nominal scale): значения — это просто метки, которые нельзя упорядочить. Допустимые операции: проверка равенства, подсчет частот, мода. Примеры: пол, цвет глаз, марка автомобиля.
2. **Порядковая шкала** (ordinal scale): значения можно упорядочить, но нельзя сказать, на сколько одно значение больше другого. Допустимые операции: всё, что для номинальной шкалы, плюс сравнение (больше/меньше), медиана, проценти́ли. Примеры: уровень образования, воинское звание, оценка удовлетворённости.
3. **Интервальная шкала** (interval scale): значения можно упорядочить, и разности между ними имеют смысл. Но нулевая точка произвольна, поэтому нельзя говорить об отношениях. Допустимые операции: всё, что для порядковой шкалы, плюс сложение и вычитание, среднее, стандартное отклонение. Примеры: температура по Цельсию или Фаренгейту, календарные годы.
4. **Шкала отношений** (ratio scale): значения можно упорядочить, разности имеют смысл, и есть абсолютный нуль. Допустимые операции: всё, что для интервальной шкалы, плюс умножение и деление, коэффициент вариации. Примеры: масса, рост, время, температура по Кельвину.

Понимание шкалы измерений важно, потому что от неё зависит, какие статистические методы допустимы. Например, нельзя вычислять среднее для номинальных данных, нельзя вычислять коэффициент вариации для интервальных данных.

Таблица 3: Типы переменных в EDA

Тип	Описание	Примеры
Количественные	Принимают значения на некотором интервале. Можно выполнять арифметические операции.	Температура, вес, рост
Дискретные	Принимают только целые значения.	Количество детей, число посещений
Категориальные	Принимают значения из конечного набора.	
<i>Номинальные</i>	Значения не имеют порядка.	Цвет, страна, пол
<i>Порядковые</i>	Значения имеют порядок, но расстояния не определены.	Уровень образования, оценка удовлетворенности

2.5 Практический пример: данные NSFG

Downey использует данные Национального исследования роста семей (NSFG) как основной пример. Это **кросс-секционное исследование**, которое дает «снимок» популяции в определенный момент времени.

Ключевые переменные NSFG:

- `caseid` — идентификатор респондента (категориальная, номинальная)
- `prglngth` — продолжительность беременности в неделях (количественная, дискретная)
- `outcome` — исход беременности (1 = живорождение) (категориальная)
- `birthord` — порядковый номер рождения (количественная, дискретная)
- `birthwgt_lb` и `birthwgt_oz` — вес при рождении (количественная)
- `agepreg` — возраст матери (количественная, непрерывная)
- `finalwgt` — статистический вес респондента (количественная)

2.6 Особенности кросс-секционных данных

Кросс-секционное исследование (cross-sectional study) — это тип обсервационного исследования, в котором данные собираются в один момент времени. Основные особенности:

- **Снимок популяции:** мы видим состояние популяции в конкретный момент, но не можем проследить изменения во времени.

- **Репрезентативность:** выборка должна быть репрезентативной для популяции. Для этого используются вероятностные схемы отбора (стратифицированная выборка, кластерная выборка).
- **Статистические веса:** в NSFG каждая респондентка имеет вес `finalwgt`, который показывает, сколько людей в популяции она представляет. Это необходимо, потому что разные группы населения имели разные вероятности попадания в выборку.
- **Ограничения:** нельзя установить причинно-следственные связи, можно только выявить корреляции.

2.7 Другие типы исследований

Помимо кросс-секционных, существуют другие типы исследований:

- **Продольные (лонгитюдные) исследования:** одни и те же объекты наблюдаются в течение длительного времени. Пример: исследование здоровья детей с рождения до взрослого возраста.
- **Когортные исследования:** наблюдение за группой людей (когортой), объединённых общим событием (например, годом рождения).
- **Экспериментальные исследования:** исследователь активно вмешивается в процесс, контролируя факторы. Пример: рандомизированное контролируемое испытание (РКИ).
- **Обсервационные исследования:** исследователь только наблюдает, не вмешиваясь. Пример: когортные, случай-контроль, кросс-секционные.

3 Базовые предположения измерительного процесса

3.1 Четыре фундаментальных предположения

Любой измерительный процесс, какой бы сложной ни была научная или инженерная задача, основан на четырех фундаментальных предположениях. Согласно NIST Handbook, данные должны «вести себя» как:

1. **Случайные извлечения (Random drawings).** Наблюдения должны быть независимы друг от друга. Значение одного наблюдения не должно влиять на значение другого. Это предположение является самым важным, но, по иронии судьбы, оно же и наименее проверяемое.
2. **Фиксированное распределение (Fixed distribution).** Данные должны быть получены из одного и того же распределения. Форма распределения не должна меняться со временем или в зависимости от других факторов.

3. **Фиксированное положение (Fixed location)**. Среднее значение (или другое положение) распределения должно быть постоянным. Не должно быть тренда, дрейфа или систематических сдвигов.
4. **Фиксированная вариация (Fixed variation)**. Разброс данных (стандартное отклонение) должен быть постоянным. Не должно быть увеличения или уменьшения разброса со временем.

Важно понимать, что эти предположения относятся к **ошибкам** модели, а не к самим данным. Если мы строим сложную модель $Y = f(X_1, \dots, X_k) + \text{error}$, то мы требуем, чтобы именно ошибки (остатки) удовлетворяли этим четырем условиям. Если остатки ведут себя как случайные извлечения из фиксированного распределения с фиксированным положением и вариацией, значит, модель адекватна.

Ключевое понимание: Эти предположения относятся к **ошибкам** модели.

Если остатки модели ведут себя в соответствии с четырьмя предположениями, модель адекватна.

3.2 Подробное описание каждого предположения

3.2.1 Случайность

Предположение случайности означает, что наблюдения независимы друг от друга. Математически это означает, что совместная функция распределения факторизуется:

$$F(y_1, y_2, \dots, y_n) = F(y_1) \cdot F(y_2) \cdot \dots \cdot F(y_n) \quad (1)$$

Если это не так, то наблюдения коррелированы. Наиболее частый случай нарушения случайности — **автокорреляция** во временных рядах, когда значение Y_t зависит от Y_{t-1} .

Почему это предположение самое важное? Потому что большинство статистических тестов и оценок предполагают независимость. Если независимости нет, то:

- Стандартные ошибки оценок занижаются.
- Доверительные интервалы становятся слишком узкими.
- р-значения становятся невалидными.
- Эффективный размер выборки меньше номинального.

3.2.2 Фиксированное распределение

Предположение фиксированного распределения означает, что все наблюдения происходят из одного и того же вероятностного распределения. Форма распределения не

меняется от наблюдения к наблюдению. Это не означает, что распределение должно быть нормальным — оно может быть любым, но оно должно быть одним и тем же.

Нарушение этого предположения может происходить, например, когда мы смешиваем данные из двух разных популяций (например, измерения, сделанные разными приборами, или данные до и после вмешательства).

3.2.3 Фиксированное положение

Предположение фиксированного положения означает, что центральная тенденция (среднее или медиана) не меняется со временем или от наблюдения к наблюдению. Если есть тренд (например, температура растёт из-за глобального потепления), то это предположение нарушается.

Нарушение фиксированного положения может быть вызвано:

- Дрейфом прибора (instrument drift).
- Сезонными колебаниями.
- Износом оборудования.
- Изменением внешних условий.

3.2.4 Фиксированная вариация

Предположение фиксированной вариации означает, что разброс данных (стандартное отклонение) не меняется. Если вариация растёт со временем (например, процесс становится менее стабильным), это предположение нарушается.

Нарушение фиксированной вариации называется **гетероскедастичностью**. В регрессионном анализе это приводит к неэффективным оценкам и неверным стандартным ошибкам.

3.3 Почему проверка предположений критически важна

Проверка этих предположений — не формальность, а фундаментальная необходимость, без которой любой статистический анализ становится рискованным.

Во-первых, предсказуемость. Если все четыре предположения выполняются, процесс находится в **статистическом контроле** и является **предсказуемым**. Мы можем делать вероятностные утверждения не только о прошлом, но и о будущем. Мы можем сказать: «с вероятностью 95% следующее измерение будет в пределах таких-то границ». Это имеет огромное практическое значение в промышленности, медицине, финансах и других областях.

Во-вторых, валидность выводов. Если предположения не выполняются, процесс дрейфует (по положению, вариации или распределению), он непредсказуем и вышел из-под контроля. Любые выводы, сделанные на основе таких данных, будут невалидными.

Оценки среднего, стандартного отклонения или распределения будут бессмысленными или даже вводящими в заблуждение.

В-третьих, связь с моделью. Предположения дают нам инструмент для валидации модели. Если остатки модели ведут себя в соответствии с четырьмя предположениями, модель хорошая. Если нет — модель нужно улучшать.

3.4 Последствия нарушения предположений

3.4.1 Нарушение случайности

Случайность — самое важное предположение, но, как отмечают авторы NIST Handbook, оно «наименее проверяемо». Если данные не случайны, это имеет катастрофические последствия для любого анализа:

- Все стандартные статистические тесты становятся невалидными. Тесты предполагают независимость наблюдений, а если ее нет, р-значения и уровни значимости ничего не значат.
- Рассчитанные неопределенности становятся бессмысленными. Классическая формула $s(\bar{Y}) = s/\sqrt{N}$ дает оптимистично маленькие значения, потому что эффективный размер выборки меньше номинального.
- Расчетный минимальный размер выборки становится бессмысленным.
- Простая модель $Y = \text{constant} + \text{error}$ становится невалидной.
- Оценки параметров становятся подозрительными.

Особый случай нарушения случайности — **автокорреляция**. Это ситуация, когда значение Y_t зависит от Y_{t-1} (или от Y_{t-k}). Это означает, что соседние наблюдения связаны друг с другом. Тогда:

- Мы не имеем n независимых наблюдений — у нас меньше информации, чем кажется.
- Могут быть обнаруженные «мусорные» выбросы (junk outliers).
- Могут быть обнаруженные «информативные» выбросы (information-rich outliers).

3.4.2 Нарушение фиксированного положения

Если положение не фиксировано, это означает, что среднее значение дрейфует со временем. Последствия:

- Единственная оценка среднего становится бессмысленной — она описывает среднее за весь период, но не отражает реального состояния процесса в конкретный момент.

- Выбор оценки положения (например, среднего) может быть неоптимальным.
- Обычная формула для стандартной ошибки среднего дает заниженные значения.
- Оценка среднего может быть смещенной.

3.4.3 Нарушение фиксированной вариации

Если вариация не фиксирована, стандартное отклонение меняется со временем. Последствия:

- Оценка стандартного отклонения становится бессмысленной.
- Оценка может быть плохой и смещенной.
- Доверительные интервалы становятся невалидными.

3.4.4 Нарушение распределения

Если распределение не фиксировано или не является нормальным, это влияет на выбор оптимальной оценки положения. Например, для распределения Коши среднее — ужасная оценка положения, а медиана — отличная. Для равномерного распределения лучшая оценка — *midrange*. Для нормального распределения — среднее. NIST Handbook приводит наглядные примеры:

- Для нормальных данных: среднее = 0.005, медиана = -0.010, мода = -0.144 (различия малы)
- Для экспоненциальных данных: среднее = 1.001, медиана = 0.684, мода = 0.254 (различия огромны)
- Для данных Коши: среднее = 3.70, медиана = -0.016 (среднее полностью бессмысленно)

3.5 Техники проверки предположений: 4-Plot

Для проверки четырех предположений используются четыре EDA-графика, которые обычно размещаются на одной странице (это называется **4-Plot**):

1. **График последовательности (Run Sequence Plot)** — проверка фиксированного положения и вариации.
2. **График с лагом (Lag Plot)** — проверка случайности.
3. **Гистограмма (Histogram)** — проверка распределения.
4. **Нормальный вероятностный график (Normal Probability Plot)** — проверка нормальности.




Рис. 1: 4-Plot: Run Sequence Plot, Lag Plot, Histogram, Normal Probability Plot

Интерпретация 4-Plot:

- **Run Sequence Plot:** Проверяет фиксированное положение и вариацию. График должен быть «плоским» с постоянным разбросом.
- **Lag Plot:** Проверяет случайность. Должен быть хаотичным, без структуры.
- **Histogram:** Проверяет распределение. Должна быть колоколообразная форма для нормального распределения.
- **Normal Probability Plot:** Проверяет нормальность. Точки должны лежать на прямой.

3.6 Дополнительные инструменты проверки предположений

Помимо 4-Plot, для проверки предположений используются и другие инструменты:

- **Тест Шапиро-Уилка** — формальный тест на нормальность. Нулевая гипотеза: данные распределены нормально. Если p -значение < 0.05 , гипотеза отвергается.
- **Тест Колмогорова-Смирнова** — проверка соответствия эмпирического распределения теоретическому.
- **Тест Дурбина-Уотсона** — проверка автокорреляции остатков.
- **Тест Бройша-Пагана** — проверка гетероскедастичности.
- **Тест Уайта** — общий тест на гетероскедастичность.
- **QQ-plot** — график квантиль-квантиль для сравнения распределений.

4 Описательная статистика

Описательная статистика — это фундамент, на котором строится EDA. Она позволяет количественно охарактеризовать данные: где их центр, как они разбросаны, какова их форма.

4.1 Меры центральной тенденции (Location)

Меры центральной тенденции показывают, где находится «центр» данных. Но что такое «центр»? Оказывается, ответ зависит от распределения данных.

4.1.1 Среднее арифметическое (Mean)

Среднее арифметическое — это сумма всех значений, деленная на их количество:

$$\bar{Y} = \frac{1}{N} \sum_{i=1}^N Y_i \quad (2)$$

Когда использовать: Среднее — оптимальная оценка для **симметричных** распределений с **легкими хвостами**, особенно для нормального распределения. Для нормального распределения среднее является несмещенной и наиболее эффективной оценкой положения.

Когда не использовать: Среднее **чувствительно к выбросам**. Одно экстремальное значение может сильно сместить среднее. Для распределений с тяжелыми хвостами (например, распределение Коши) среднее вообще перестает быть полезной оценкой.

Математическое обоснование: Среднее является решением задачи минимизации среднеквадратичной ошибки:

$$\bar{Y} = \arg \min_c \sum_{i=1}^N (Y_i - c)^2 \quad (3)$$

Пример из NIST Handbook: Для нормальных данных среднее равно 0.005, медиана равна -0.010, мода равна -0.144. Различия между оценками малы, что говорит о симметричности распределения. Для экспоненциальных данных среднее = 1.001, медиана = 0.684, мода = 0.254. Различия огромны, что говорит об асимметрии распределения.

Свойства среднего:

- $\sum_{i=1}^N (Y_i - \bar{Y}) = 0$ (сумма отклонений от среднего равна нулю).
- $\sum_{i=1}^N (Y_i - \bar{Y})^2$ минимальна среди всех возможных констант.
- Среднее линейно: $\overline{aY + b} = a\bar{Y} + b$.
- Среднее чувствительно к каждому значению, включая выбросы.

4.1.2 Медиана (Median)

Медиана — это значение, которое делит упорядоченный набор данных пополам. Половина данных меньше медианы, половина — больше.

$$\text{Median} = \begin{cases} Y_{(N+1)/2}, & \text{если } N \text{ нечетное} \\ \frac{Y_{(N/2)} + Y_{(N/2)+1}}{2}, & \text{если } N \text{ четное} \end{cases} \quad (4)$$

Когда использовать: Медиана — **устойчивая** (робастная) оценка положения. Она почти не чувствительна к выбросам. Лучшая оценка для **асимметричных** распределений (экспоненциальное, логнормальное) и для распределений с **тяжелыми хвостами** (распределение Коши).

Математическое обоснование: Медиана является решением задачи минимизации среднего абсолютного отклонения:

$$\text{Median} = \arg \min_c \sum_{i=1}^N |Y_i - c| \quad (5)$$

Пример из NIST Handbook: Для распределения Коши среднее = 3.70, медиана = -0.016. Огромное различие! При этом 3.70 — это значение, которое сильно далеко от основной массы данных. Медиана же дает разумную оценку центра.

Свойства медианы:

- Медиана не чувствительна к выбросам.
- Сумма абсолютных отклонений от медианы минимальна.
- Медиана является 50-м перцентилем.
- Для симметричного распределения медиана совпадает со средним.

4.1.3 Мода (Mode)

Мода — это наиболее часто встречающееся значение. Для непрерывных данных мода определяется как середина интервала гистограммы с наибольшей частотой.

Когда использовать: Мода используется скорее в качественных целях. Например, если гистограмма имеет один явный пик, мы говорим об одномодальном распределении. Если два пика — о бимодальном, что может указывать на смесь двух распределений.

Свойства моды:

- Мода может быть не единственной (бимодальные, полимодальные распределения).
- Мода может не существовать (например, для равномерного распределения).
- Мода — единственная мера центра, применимая к номинальным данным.

4.1.4 Midrange

Midrange — это полусумма минимума и максимума:

$$\text{Midrange} = \frac{Y_{\min} + Y_{\max}}{2} \quad (6)$$

Когда использовать: Midrange — оптимальная оценка положения для **равномерного распределения**. Для других распределений она крайне чувствительна к выбросам и обычно не используется.

Таблица 4: Выбор меры центральной тенденции в зависимости от распределения

Распределение	Лучшая мера	Пример из NIST
Нормальное	Среднее	Mean = 0.005, Median = -0.010
Равномерное	Midrange	Оптимальна для равномерного распределения
Асимметричное	Медиана	Экспоненциальное: Mean = 1.001, Median = 0.684
Тяжелохвостое	Медиана	Коши: Mean = 3.70, Median = -0.016

4.2 Меры разброса (Scale)

Меры разброса показывают, насколько данные распределены вокруг центра.

4.2.1 Дисперсия (Variance)

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (Y_i - \bar{Y})^2 \quad (7)$$

Свойства:

- Имеет квадрат единиц измерения. Если данные в метрах, дисперсия в квадратных метрах.
- **Сильно чувствительна к выбросам.** Одно экстремальное значение может сильно увеличить дисперсию.
- Оптимальна для нормального распределения.
- $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$.
- $\text{Var}(aX + b) = a^2\text{Var}(X)$.

Смещенная и несмещенная оценки:

- Смещенная (выборочная) дисперсия: $\sigma^2 = \frac{1}{N} \sum_{i=1}^N (Y_i - \bar{Y})^2$
- Несмещенная дисперсия: $s^2 = \frac{1}{N-1} \sum_{i=1}^N (Y_i - \bar{Y})^2$

Пример из Think Stats: Для продолжительности беременности в NSFG дисперсия = 7.3 «квадратных недель», что трудно интерпретировать. Downey отмечает: «Дисперсия полезна в некоторых вычислениях, но она не является хорошей сводной статистикой».

4.2.2 Стандартное отклонение (Standard Deviation)

$$s = \sqrt{s^2} \quad (8)$$

Свойства:

- Восстанавливает единицы измерения.
- Чувствительна к выбросам, но менее, чем дисперсия (потому что корень частично компенсирует возведение в квадрат).
- Для нормальных данных в примере NIST: $s = 0.997$.
- $SD(aX + b) = |a|SD(X)$.

Пример из Think Stats: Для продолжительности беременности в NSFG: среднее = 38.6 недель, стандартное отклонение = 2.7 недель. Это означает, что отклонения на 2-3 недели от среднего являются обычным явлением.

4.2.3 Интерквартильный размах (IQR)

$$IQR = Q_3 - Q_1 \quad (9)$$

где Q_1 — 25-й процентиль, Q_3 — 75-й процентиль.

Свойства:

- **Робастная** мера разброса. Не чувствительна к выбросам.
- Используется в Box Plot для определения границ «усов» и выбросов.
- Содержит 50% центральных данных.
- Связана с медианой так же, как стандартное отклонение со средним.

4.2.4 Другие меры разброса

Размах (Range): $Y_{\max} - Y_{\min}$. Сильно зависит от выбросов, но прост в вычислении.

Среднее абсолютное отклонение (AAD):

$$AAD = \frac{1}{N} \sum_{i=1}^N |Y_i - \bar{Y}| \quad (10)$$

Менее чувствительна к выбросам, чем стандартное отклонение.

Медианное абсолютное отклонение (MAD):

$$MAD = \text{median}(|Y_i - \text{median}(Y)|) \quad (11)$$

Наиболее устойчивая к выбросам мера разброса. Для нормального распределения $MAD \approx 0.6745\sigma$.

Коэффициент вариации (CV):

$$CV = \frac{s}{\bar{Y}} \quad (12)$$

Безразмерная мера разброса. Позволяет сравнивать разброс переменных с разными единицами измерения. Имеет смысл только для шкалы отношений (когда есть абсолютный нуль).

Квартильный коэффициент вариации:

$$QCV = \frac{Q_3 - Q_1}{Q_3 + Q_1} \quad (13)$$

Робастная версия коэффициента вариации.

4.3 Меры формы распределения**4.3.1 Асимметрия (Skewness)**

Асимметрия показывает, насколько распределение несимметрично:

$$g_1 = \frac{1}{N} \sum_{i=1}^N \left(\frac{Y_i - \bar{Y}}{s} \right)^3 \quad (14)$$

- $g_1 = 0$: Симметричное распределение (нормальное).
- $g_1 > 0$: Положительная асимметрия. Правый хвост длиннее левого. Это часто бывает для данных с нижней границей (например, время до отказа).
- $g_1 < 0$: Отрицательная асимметрия. Левый хвост длиннее правого.

Пример из NIST Handbook: Для экспоненциальных данных асимметрия = 2.0. Для нормальных данных асимметрия = 0.03.

Правило большого пальца: Если $|g_1| > 2 \cdot SE(g_1)$, где $SE(g_1) = \sqrt{6/N}$, асимметрия статистически значима.




Рис. 2: Типы асимметрии распределений

4.3.2 Эксцесс (Kurtosis)

Эксцесс показывает, насколько распределение островершинное или плосковершинное:

$$g_2 = \frac{1}{N} \sum_{i=1}^N \left(\frac{Y_i - \bar{Y}}{s} \right)^4 \quad (15)$$

- $g_2 = 3$: Нормальное распределение (мезокуртическое).
- $g_2 > 3$: Острые пики, тяжелые хвосты (лептокуртическое). Пример: распределение Коши ($g_2 \approx 6693$ — экстремально большие значения из-за тяжелых хвостов).
- $g_2 < 3$: Плоские вершины (платикуртическое). Пример: равномерное распределение ($g_2 = 1.8$).

Избыточный эксцесс: $g_2 - 3$. Для нормального распределения избыточный эксцесс равен 0.

Правило большого пальца: Если $|g_2 - 3| > 2 \cdot SE(g_2)$, где $SE(g_2) = \sqrt{24/N}$, эксцесс статистически значим.




Рис. 3: Типы эксцесса распределений

4.4 Пятичисловая сводка

Пятичисловая сводка (five-number summary) — это набор из пяти статистик, который даёт компактное описание распределения:

1. Минимум ($Y_{\min}$)
2. Первый квартиль (Q_1)
3. Медиана (Q_2)
4. Третий квартиль (Q_3)
5. Максимум ($Y_{\max}$)

Пятичисловая сводка лежит в основе ящика с усами (Box Plot). Она гораздо более информативна, чем просто среднее и стандартное отклонение, потому что показывает не только центр и разброс, но и форму распределения (через соотношение между квартилями).

4.5 Сравнение мер центральной тенденции и разброса

Таблица 5: Сравнение мер центральной тенденции и разброса

Мера	Чувствительность к выбросам	Оптимальна для	Единицы
Среднее	Высокая	Нормальное	Как у данных
Медиана	Низкая	Асимметричное, тяжелые хвосты	Как у данных
Мода	Низкая	Категориальные данные	Как у данных
Midrange	Очень высокая	Равномерное	Как у данных
Дисперсия	Очень высокая	Нормальное	Квадрат единиц
Стандартное отклонение	Высокая	Нормальное	Как у данных
IQR	Низкая	Любое	Как у данных
MAD	Очень низкая	Любое	Как у данных
Размах	Очень высокая	Любое	Как у данных

5 Гистограммы: построение и интерпретация

5.1 Определение и математическое обоснование

Гистограмма — это графическое представление распределения данных, где диапазон данных разбивается на k интервалов (bins), и для каждого интервала подсчитывается количество точек.

Математическое определение: Пусть $x_1, x_2, \dots, x_n$ — выборка. Разобьем диапазон $[x_{(1)}, x_{(n)}]$ на k интервалов $I_j = [a_{j-1}, a_j]$. Тогда гистограмма определяется как:

$$h_j = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(x_i \in I_j) \quad (16)$$

где $\mathbf{1}(\cdot)$ — индикаторная функция.

Правило выбора числа интервалов:

1. **Правило Стёрджеса:**

$$k = \lceil \log_2 n + 1 \rceil \quad (17)$$

2. **Правило Скотта:**

$$h = \frac{3.5\sigma}{n^{1/3}} \quad (18)$$

3. **Правило Фридмана-Диакониса:**

$$h = \frac{2 \cdot IQR}{n^{1/3}} \quad (19)$$




Рис. 4: Гистограмма веса при рождении с наложенной нормальной кривой

5.2 Влияние ширины интервала

Выбор ширины интервала (bin width) критически важен для интерпретации гистограммы. Слишком узкие интервалы дают «шумную» гистограмму, слишком широкие — скрывают структуру.

- **Слишком мало интервалов:** гистограмма становится слишком гладкой, теряются детали (например, бимодальность может остаться незамеченной).
- **Слишком много интервалов:** гистограмма становится «рваной», случайные флуктуации выборки создают ложные пики.
- **Оптимальное число:** компромисс между смещением и дисперсией. Правила Стёрджеса, Скотта и Фридмана-Диакониса дают разумные оценки.

5.3 Детальная интерпретация гистограмм

NIST Handbook описывает несколько типов гистограмм и их интерпретацию.

5.3.1 Нормальное распределение (симметричное, умеренные хвосты)

Гистограмма имеет классическую колоколообразную форму. Большая часть данных сосредоточена в центре, частоты плавно убывают к краям.

Пример: Вес при рождении (рисунок 2.1 в Think Stats). Наиболее частое значение (мода) — 7 фунтов. Распределение приблизительно колоколообразное, но асимметричное — хвост длиннее влево.

Рекомендация: Если гистограмма такая, следующий шаг — построить нормальный вероятностный график для подтверждения нормальности.

5.3.2 Симметричное, короткие хвосты

«Обрезанный» вид — хвосты обрываются резко.

Пример: Унции при рождении — распределение должно быть равномерным, но из-за округления 0 более частый, а 1 и 15 менее частые.

Рекомендация: Для таких данных оптимальной оценкой положения является midrange (полусумма минимума и максимума).

5.3.3 Симметричное, длинные хвосты

Гистограмма имеет тяжелые хвосты — точки далеко от центра.

Пример: Распределение Коши. Для таких данных среднее — ужасная оценка, нужно использовать медиану.

5.3.4 Бимодальное распределение

На гистограмме два ярко выраженных пика. Это может указывать на:

1. Смесь двух распределений (например, две подгруппы в данных).
2. Наличие синусоидальной компоненты в данных.

Рекомендация: Проверить синусоидальность с помощью Lag Plot или Spectral Plot.




Рис. 5: Бимодальное распределение

5.3.5 Асимметрия вправо

Правый хвост длиннее левого. Часто возникает из-за нижней границы данных.

Пример: Возраст матери — большинство матерей в возрасте 20 лет, меньше в 30.

Рекомендация: Рассмотреть преобразование Box-Cox.

5.3.6 Асимметрия влево

Левый хвост длиннее правого. Рекомендации аналогичны.

5.4 Выбросы и их обнаружение

Как отмечает Downey: «Прежде чем продолжить, полезно проверить наличие выбросов — экстремальных значений, которые могут быть ошибками измерения или редкими событиями».

Пример из NSFG: В данных о продолжительности беременности были найдены значения 0, 4, 9, 13 недель — явные ошибки кодирования. На другом конце диапазона — 50 недель, что медицински маловероятно.

Методы обнаружения выбросов:

1. Визуальный анализ гистограммы
2. Box Plot (точки за пределами $1.5 \times IQR$)
3. Z-оценка: $|z| > 3$ указывает на выброс

$$z_i = \frac{x_i - \bar{x}}{s} \quad (20)$$

4. Модифицированная Z-оценка (с использованием MAD):

$$M_i = \frac{0.6745(x_i - \tilde{x})}{MAD} \quad (21)$$

5. Тест Граббса для проверки наличия одного выброса
6. Тест Титъена-Мура для множественных выбросов

5.5 Преобразования данных

Если данные асимметричны или имеют гетероскедастичность, полезно применить преобразование. Основные преобразования:

- **Логарифмическое:** $Y' = \log(Y)$. Применяется для правосторонней асимметрии, стабилизирует вариацию.
- **Квадратный корень:** $Y' = \sqrt{Y}$. Применяется для данных подсчёта (распределение Пуассона).

- **Обратное:** $Y' = 1/Y$. Сильно сжимает большие значения.
- **Бох-Сох:** семейство преобразований

$$Y' = \begin{cases} \frac{Y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \log(Y), & \lambda = 0 \end{cases} \quad (22)$$

Параметр λ подбирается так, чтобы максимизировать нормальность.

6 Ящик с усами (Box Plot)

6.1 Определение и построение

Box Plot — графическое представление распределения, основанное на пяти статистиках: минимуме, первом квартиле, медиане, третьем квартиле и максимуме.

Построение:

1. Находятся Q_1 (25-й перцентиль), медиана Q_2 (50-й) и Q_3 (75-й).
2. Рисуется прямоугольник («ящик») от Q_1 до Q_3 (50% данных).
3. Внутри ящика — линия на уровне медианы.
4. $IQR = Q_3 - Q_1$.
5. Границы «усов»: $L = Q_1 - 1.5 \times IQR$, $U = Q_3 + 1.5 \times IQR$.
6. «Усы» — до минимального значения $> L$ и максимального $< U$.
7. Точки за пределами L и U — выбросы.

Математическое обоснование: Коэффициент 1.5 выбран эмпирически и соответствует примерно $\pm 2.7\sigma$ для нормального распределения.




Рис. 6: Структура Box Plot

6.2 Использование Box Plot для сравнения распределений

Box Plot позволяет:

1. **Сравнивать распределения по группам.** Можно сразу увидеть, у какой группы медиана больше, у какой больше разброс.

2. **Обнаруживать выбросы.** Box Plot автоматически отмечает потенциальные выбросы.
3. **Оценивать симметричность.** Если медиана находится ровно посередине ящика, распределение симметрично. Если смещена — есть асимметрия.




Рис. 7: Сравнение распределений с помощью Box Plot

6.3 Модификации Box Plot

Помимо классического Box Plot, существуют его модификации:

- **Box Plot с усами на процентилях:** вместо 1.5 IQR используются 10-й и 90-й процентиля.
- **Notched Box Plot:** ящик сужается в области медианы. Если выемки двух групп не перекрываются, различие медиан статистически значимо.
- **Violin Plot:** комбинация Box Plot и KDE. Показывает не только квартили, но и форму распределения.
- **Beanplot:** комбинация Box Plot и одномерной диаграммы рассеяния.

7 Кумулятивные функции распределения (CDF)

7.1 Определение и свойства

Кумулятивная функция распределения (Cumulative Distribution Function, CDF) отображает значение на его процентильный ранг:

$$F(x) = P(X \leq x) \quad (23)$$

Свойства CDF:

1. $0 \leq F(x) \leq 1$ для всех x
2. $F(x)$ — неубывающая функция

3. $\lim_{x \rightarrow -\infty} F(x) = 0$
4. $\lim_{x \rightarrow +\infty} F(x) = 1$
5. $P(a < X \leq b) = F(b) - F(a)$
6. $F(x)$ непрерывна справа

7.2 Преимущества CDF перед PMF

Downey отмечает: «PMF работают хорошо, если количество значений мало. Но по мере увеличения числа значений вероятность, связанная с каждым значением, уменьшается, и эффект случайного шума возрастает».

Преимущества CDF:

- CDF можно построить для любого размера выборки.
- CDF не зависит от выбора ширины интервала (в отличие от гистограммы).
- CDF позволяет легко находить процентиля.
- CDF позволяет сравнивать распределения (если одна CDF выше другой, это стохастическое доминирование).
- CDF сглаживает шум, присущий PMF.




Рис. 8: CDF продолжительности беременности для разных групп

7.3 Процентиля и квантили

Процентиль — значение, ниже которого находится заданный процент данных:

$$p\text{-й процентиль} = F^{-1}(p/100) \quad (24)$$

Квантиль — обобщение процентиля для произвольной вероятности:

$$Q(p) = F^{-1}(p), \quad p \in [0, 1] \quad (25)$$

Важные квантили:

- Медиана: $Q(0.5)$
- Нижний квартиль: $Q(0.25)$
- Верхний квартиль: $Q(0.75)$
- Децили: $Q(0.1), Q(0.2), \dots, Q(0.9)$
- Перцентили: $Q(0.01), Q(0.02), \dots, Q(0.99)$

7.4 Сравнение распределений с помощью CDF

Если одна CDF всегда выше другой, это означает **стохастическое доминирование первого порядка**. Это означает, что значения в первом распределении систематически меньше (или больше) значений во втором.

Формально, $F_X(t) \leq F_Y(t)$ для всех t означает, что X стохастически доминирует Y (значения X систематически больше значений Y).

7.5 Эмпирическая CDF

Эмпирическая CDF (ECDF) строится по выборке:

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(X_i \leq x) \quad (26)$$

ECDF — ступенчатая функция, которая увеличивается на $1/n$ в каждой точке данных. При $n \rightarrow \infty$ ECDF сходится к истинной CDF (теорема Гливенко-Кантелли).

7.6 Генерация случайных чисел из CDF

Метод обратного преобразования:

1. Сгенерировать $u \sim U(0, 1)$
2. Вернуть $x = F^{-1}(u)$

Этот метод работает для любого распределения, для которого известна обратная CDF. Он широко используется в имитационном моделировании.

8 Функции плотности вероятности (PDF) и KDE

8.1 PDF как производная CDF

Функция плотности вероятности (Probability Density Function, PDF) — это производная CDF:

$$f(x) = \frac{d}{dx} F(x) \quad (27)$$

Свойства PDF:

1. $f(x) \geq 0$ для всех x
2. $\int_{-\infty}^{\infty} f(x)dx = 1$
3. $P(a \leq X \leq b) = \int_a^b f(x)dx$

Связь между PDF и вероятностью: В отличие от PMF, PDF не дает вероятности в точке — она дает **плотность** вероятности. Вероятность получается интегрированием PDF на интервале.

8.2 Нормальное распределение

PDF нормального распределения:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right] \quad (28)$$

Свойства нормального распределения:

- Симметрично относительно μ
- Мода, медиана и среднее совпадают: $\text{Mode} = \text{Median} = \mu$
- Точки перегиба при $x = \mu \pm \sigma$
- Правило 68 – 95 – 99.7: 68% данных в $[\mu - \sigma, \mu + \sigma]$, 95% в $[\mu - 2\sigma, \mu + 2\sigma]$, 99.7% в $[\mu - 3\sigma, \mu + 3\sigma]$
- Асимметрия $g_1 = 0$, эксцесс $g_2 = 3$
- Линейная комбинация нормальных случайных величин также нормальна




Рис. 9: PDF нормального распределения с разными параметрами

8.3 Другие важные распределения

- **Экспоненциальное распределение:** $f(x) = \lambda e^{-\lambda x}$, $x \geq 0$. Используется для моделирования времени между событиями. Асимметрия $g_1 = 2$, эксцесс $g_2 = 9$.
- **Равномерное распределение:** $f(x) = \frac{1}{b-a}$ на $[a, b]$. Асимметрия $g_1 = 0$, эксцесс $g_2 = 1.8$.
- **Логнормальное распределение:** если $Y = \ln X$ нормально, то X логнормально. Используется для моделирования доходов, размеров частиц.
- **Распределение Вейбулла:** $f(x) = \frac{k}{\lambda} \left(\frac{x}{\lambda}\right)^{k-1} e^{-(x/\lambda)^k}$. Используется в анализе надёжности.
- **Гамма-распределение:** обобщение экспоненциального. Используется для моделирования времени до k -го события.
- **Бета-распределение:** определено на $[0, 1]$. Используется для моделирования вероятностей.

8.4 Оценка плотности ядром (KDE)

Kernel Density Estimation (KDE) — алгоритм, который по выборке строит сглаженную оценку PDF:

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right) \quad (29)$$

где K — ядро (обычно гауссовское), h — ширина окна (bandwidth).

Свойства KDE:

- Сходится к истинной PDF при $n \rightarrow \infty$ и $h \rightarrow 0$
- Выбор h критически важен (компромисс смещение-дисперсия)
- Рекомендованное правило: $h = 1.06\sigma n^{-1/5}$ (правило Сильвермана)

Популярные ядра:

- Гауссовское: $K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}$
- Епанечниково: $K(u) = \frac{3}{4}(1 - u^2)$ при $|u| \leq 1$
- Треугольное: $K(u) = 1 - |u|$ при $|u| \leq 1$
- Косинусное: $K(u) = \frac{\pi}{4} \cos\left(\frac{\pi u}{2}\right)$ при $|u| \leq 1$

8.5 Сравнение KDE и гистограммы

Таблица 6: Сравнение гистограммы и KDE

Критерий	Гистограмма	KDE
Гладкость	Ступенчатая	Гладкая
Выбор параметра	Ширина бина	Ширина окна
Чувствительность к выбору	Высокая	Высокая
Интерпретация	Частоты	Плотность
Сходимость	Зависит от числа бинов	Сходится при $n \rightarrow \infty$

9 Анализ взаимосвязей

9.1 Диаграммы рассеяния

Диаграмма рассеяния — простейший способ визуализации взаимосвязи между двумя переменными.

Проблемы визуализации и их решения:

1. **Перекрытие точек (saturation)** — решается прозрачностью (alpha-каналом)
2. **Округление данных** — решается джиттерингом (добавлением случайного шума)
3. **Большие данные** — решается hexbin-графиками

Диаграмма рассеяния: рост и вес




Рис. 10: Диаграмма рассеяния с линейной моделью

9.2 Корреляция

9.2.1 Ковариация

$$Cov(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (30)$$

Свойства ковариации:

- $Cov(X, X) = Var(X)$

- $Cov(X, Y) = Cov(Y, X)$
- $Cov(aX + b, cY + d) = ac \cdot Cov(X, Y)$
- Если X и Y независимы, то $Cov(X, Y) = 0$
- Обратное неверно: $Cov(X, Y) = 0$ не означает независимость

9.2.2 Корреляция Пирсона

$$\rho = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} \quad (31)$$

Свойства корреляции Пирсона:

- $-1 \leq \rho \leq 1$
- $\rho = 1$: идеальная положительная корреляция
- $\rho = -1$: идеальная отрицательная корреляция
- $\rho = 0$: нет линейной корреляции
- Инвариантна к линейным преобразованиям
- Измеряет только **линейную** связь

9.2.3 Корреляция Спирмена

Использует ранги вместо значений. Более робастна к выбросам и нелинейным отношениям:

$$\rho_S = \frac{Cov(R(X), R(Y))}{\sigma_{R(X)} \sigma_{R(Y)}} \quad (32)$$

где $R(X)$ — ранги значений X .

Свойства корреляции Спирмена:

- Измеряет монотонную связь (не только линейную)
- Устойчива к выбросам
- Применима к порядковым данным
- $\rho_S = 1$: идеальная монотонная возрастающая связь
- $\rho_S = -1$: идеальная монотонная убывающая связь

9.2.4 Корреляция Кендалла

Ещё одна ранговая мера корреляции, основанная на подсчёте конкордантных и дискордантных пар:

$$\tau = \frac{C - D}{\binom{n}{2}} \quad (33)$$

где C — число конкордантных пар, D — число дискордантных пар.




Рис. 11: Типы корреляции

9.3 Корреляция и причинность

Важно: Корреляция не означает причинность. Возможные объяснения корреляции:

1. А вызывает В (прямая причинно-следственная связь)
2. В вызывает А (обратная причинно-следственная связь)
3. Скрытая переменная С вызывает и А, и В (общая причина)
4. Случайность (ложная корреляция)

Методы установления причинности:

- Рандомизированные контролируемые испытания
- Естественные эксперименты
- Временные ряды (причина должна предшествовать следствию)
- Инструментальные переменные
- Метод разности разностей (difference-in-differences)
- Регрессионный разрыв (regression discontinuity)

9.4 Матрица диаграмм рассеяния

Для анализа взаимосвязей между многими переменными используется матрица диаграмм рассеяния (scatter plot matrix). Это $k \times k$ матрица, где на пересечении i -й строки и j -го столбца находится диаграмма рассеяния переменных X_i и X_j . На диагонали обычно размещают гистограммы или ядерные оценки плотности.

Матрица рассеяния позволяет быстро оценить:

- Наличие линейных и нелинейных связей.
- Кластеры и выбросы.
- Мультиколлинеарность.

10 Практический EDA: пошаговый процесс

Downey описывает процесс EDA, который он использует при работе с новым набором данных:

10.1 1. Импорт и очистка данных

1. Загрузить данные в удобную структуру (DataFrame в pandas).
2. Проверить размерность: число строк и столбцов.
3. Проверить типы данных: числовые, категориальные, даты.
4. Обработать пропущенные значения: удалить, заполнить средним/медианой/модой, интерполировать.
5. Обработать дубликаты.
6. Проверить диапазоны значений: нет ли отрицательных значений там, где их быть не должно.
7. При необходимости преобразовать единицы измерения.

10.2 2. Исследование одной переменной

1. Построить гистограмму
2. Проверить выбросы (`Hist.Smallest()`, `Hist.Largest()`)
3. Вычислить сводные статистики (среднее, медиана, стандартное отклонение)
4. Построить CDF
5. Построить Box Plot
6. Проверить нормальность (QQ-plot, тест Шапиро-Уилка)

10.3 3. Парные исследования

1. Построить диаграммы рассеяния
2. Вычислить корреляции (Пирсона и Спирмена)
3. Построить линейные модели
4. Проверить остатки модели

10.4 4. Многомерный анализ

Множественная регрессия для учета контрольных переменных.

10.5 5. Оценка и проверка гипотез

Три ключевых вопроса:

1. Насколько велик эффект? (размер эффекта)
2. Какова вариабельность при повторении? (стандартная ошибка)
3. Может ли эффект быть случайным? (р-значение)

10.6 6. Визуализация

На этапе исследования визуализация помогает найти взаимосвязи. Затем, если эффект подтверждается, визуализация помогает донести результаты.

10.7 7. Документирование

Важно документировать все шаги EDA:

- Какие данные использовались.
- Какие преобразования применялись.
- Какие графики строились и что они показали.
- Какие гипотезы были сформулированы.
- Какие выводы сделаны.

10.8 8. Итеративность процесса

EDA — итеративный процесс. На каждом шаге могут возникать новые вопросы, требующие возврата к предыдущим этапам. Например, обнаружив бимодальность, мы можем вернуться к данным и поискать группирующую переменную.

Главный вывод из NIST Handbook и Think Stats

«Графические методы — это не просто инструменты, которые можно использовать в EDA.

Это инструменты, которые необходимо использовать для получения инсайта».

«EDA — это подход, который использует данные для выбора модели, а не наоборот».

Рекомендуемая литература

1. **Tukey, J. W. (1977).** *Exploratory Data Analysis*. Addison-Wesley.
Доступно: https://archive.org/details/exploratorydataa0000tukey_7616/mode/2up
2. **Downey, A. B. (2014).** *Think Stats: Exploratory Data Analysis in Python*, 2nd Edition. O'Reilly Media.
Доступно: <https://greenteapress.com/wp/think-stats-2/>