

Лабораторная работа № 1

«Разведочный анализ данных (EDA) и визуализация»

Цель работы

Освоить полный цикл разведочного анализа данных (EDA): проверку базовых предположений измерительного процесса, расчёт описательных статистик, построение и интерпретацию графиков (гистограмм, Box Plot, CDF, диаграмм рассеяния), выявление выбросов, аномалий и взаимосвязей, а также формулирование гипотез для дальнейшего моделирования.

Задачи

1. Изучить философию и цели разведочного анализа данных
2. Освоить проверку четырёх фундаментальных предположений измерительного процесса с помощью 4-Plot
3. Изучить меры центральной тенденции и меры разброса
4. Освоить построение и интерпретацию гистограмм, Box Plot, CDF и KDE
5. Изучить методы анализа взаимосвязей: диаграммы рассеяния и корреляции
6. Провести сравнительный анализ распределений по группам
7. Сформулировать гипотезы для дальнейшего моделирования

Исходные данные (выбрать один из датасетов)

- Вариант 1: Titanic — пассажиры «Титаника»
<https://www.kaggle.com/competitions/kbi-kaggle-titatic-2021/overview>
- Вариант 2: Boston Housing — цены на жильё
<https://www.kaggle.com/datasets/muhammadyasirsaleem/boston-house-price>
- Вариант 3: California Housing — цены на жильё
<https://www.kaggle.com/c/nn-urfu-regression/data>
- Вариант 4: Iris — размеры цветков ириса
<https://www.kaggle.com/datasets/alihamza14/iris-dataset>
- Вариант 5: Wine Quality — физико-химические свойства вин
<https://www.kaggle.com/datasets/parhamerami/red-and-white-wine-quality>
- Вариант 6: Breast Cancer Wisconsin — диагностика рака груди
<https://www.kaggle.com/datasets/sthuthimarathe/cells-dont-lie-a-data-driven-fight->
- Вариант 7: Собственный датасет (не менее 500 строк, смешанные типы признаков)

Описание выбранного датасета

- Название датасета: [указать выбранный вариант]
- Описание: [краткое описание данных]
- Количество наблюдений: [указать количество]
- Количество признаков: [указать количество]
- Тип признаков: [указать типы — количественные, дискретные, номинальные, порядковые]
- Шкалы измерений: [номинальная, порядковая, интервальная, отношений]
- Наличие пропусков: [указать количество и типы]

Методика выполнения

Часть 1: Подготовка и первичный осмотр данных

1. Загрузка данных в `pandas.DataFrame`
2. Вывод размерности, типов данных, первых и последних строк
3. Проверка пропусков и дубликатов
4. Определение типа и шкалы измерений для каждого признака
5. Анализ корректности вычисления среднего для каждого признака

Часть 2: Проверка базовых предположений (4-Plot)

1. Построение Run Sequence Plot
2. Построение Lag Plot
3. Построение гистограммы
4. Построение Normal Probability Plot
5. Интерпретация каждого графика и вывод о выполнении предположений

Часть 3: Описательная статистика

1. Расчёт мер центральной тенденции: среднее, медиана, мода
2. Расчёт мер разброса: дисперсия, стандартное отклонение, IQR, MAD, размах, коэффициент вариации
3. Сравнение среднего и медианы и вывод о форме распределения

Часть 4: Визуализация распределения

1. Построение гистограмм с различным числом бинов (столбцов)
2. Построение Box Plot и обнаружение выбросов по правилу $1.5 \cdot IQR$
3. Построение CDF и нахождение процентилей
4. Построение KDE и сравнение с гистограммой

Часть 5: Анализ взаимосвязей

1. Построение диаграмм рассеяния с линией регрессии
2. Расчёт ковариации и корреляций (Пирсон)
3. Построение матрицы диаграмм рассеяния
4. Проверка влияния выбросов на корреляцию
5. Формулирование гипотез о взаимосвязях

Часть 6: Сравнительный анализ

1. Выбор категориальной и количественной переменной
2. Построение Box Plot по группам
3. Построение CDF для каждой группы
4. Сравнение медиан и разброса
5. Интерпретация различий на основе графиков

Часть 7: Итоговый отчёт и выводы

1. Описание данных и их типов
2. Результаты проверки предположений
3. Описательные статистики и их интерпретация
4. Визуализации с подписями и выводами
5. Обнаруженные аномалии, выбросы и пропуски
6. Сформулированные гипотезы для дальнейшего анализа
7. Общий вывод о применимости моделей

Требования к отчету

Содержание отчета

1. Титульный лист
2. Цель и задачи работы
3. Описание выбранного датасета
4. Методика исследования
5. Результаты по каждой части:
 - Код реализации
 - Таблицы с результатами
 - Графики и визуализации
 - Статистические выводы
6. Сравнительный анализ и интерпретация
7. Выводы и практические рекомендации

Визуализация

- 4-Plot (Run Sequence, Lag Plot, Histogram, Normal Probability Plot)
- Гистограммы с различным числом бинов
- Box Plot (в том числе по группам)
- CDF и ECDF
- KDE и сравнение с гистограммой
- Диаграммы рассеяния и матрица рассеяния
- Графики корреляций

Аналитические таблицы

Переменная	Среднее	Медиана	Ст. откл.	IQR	MAD	Размах

Предположение	График	Результат	Вывод
Случайность	Lag Plot		
Фиксированное распределение	Histogram		
Фиксированное положение	Run Sequence Plot		
Фиксированная вариация	Run Sequence Plot		

Пара переменных	Корреляция Пирсона
-----------------	--------------------

Группа	Среднее	Медиана	Ст. откл.	IQR	Вывод
--------	---------	---------	-----------	-----	-------