

Разведочный анализ данных (EDA)

Интеллектуальные методы анализа данных

Кафедра прикладной математики и системного анализа

Сысоев А.С., к.т.н., доц.

Введение в EDA

Что такое EDA?

Разведочный анализ данных (EDA) — подход к анализу данных, использующий преимущественно графические методы для:

- Максимизации инсайта в структуру данных
- Выявления закономерностей
- Обнаружения выбросов
- Проверки предположений

«EDA — это не просто набор техник, это философия того, как мы анализируем данные»

— NIST/SEMATECH e-Handbook

Исторический контекст

- Основан Джоном Тьюки (1977)
- Книга *Exploratory Data Analysis*
- Революционный подход к статистике

Ключевое отличие EDA от классического анализа

Классический:

Проблема → Данные → **Модель** → Анализ → Выводы

EDA:

Проблема → Данные → **Анализ** → Модель → Выводы

- EDA: Данные говорят сами за себя
- **Классический**: Модель навязывается данным

1. **Максимизация инсайта в структуру данных**
2. **Выявление лежащей в основе структуры данных**
3. **Извлечение важных переменных**
4. **Обнаружение выбросов и аномалий**
5. **Проверка базовых предположений**
6. **Разработка «экономных» моделей**
7. **Определение оптимальных настроек факторов**

*«Выбросы часто являются "нашими друзьями поскольку они пытаются сообщить нам нечто важное о процессе»
— Allen B. Downey, Think Stats*

EDA против классического подхода

Критерий	Классический подход	EDA
Модель	Навязывает модели данным	Позволяет данным предложить модели
Фокус	Модель: оценка параметров	Данные: структура, выбросы
Техники	Количественные (ANOVA, t-тесты)	Графические (диаграммы, box plots)
Строгость	Строгие, формальные	Субъективные, наводящие
Обработка	Сжимает данные в несколько чисел	Использует все доступные данные
Предположения	Много строгих предположений	Мало предположений

*«Если вы не используете статистическую графику, вы жертвуете инсайтом в один или несколько аспектов структуры данных»
— NIST Handbook*

Критические функции графики

1. Визуализация структуры данных
2. Проверка предположений
3. Выбор модели
4. Обнаружение выбросов
5. Идентификация взаимосвязей
6. Коммуникация результатов


«Графические инструменты — это кратчайший путь к получению инсайта в данные»

Почему визуализация критически важна


Одинаковая статистика — разные данные!

- $\bar{X} = 9.0$, $\bar{Y} = 7.5$
- Корреляция $\rho = 0.816$
- Линейная регрессия: $Y = 3.0 + 0.5X$


Набор 1: Линейная зависимость




Набор 2: Квадратная зависимость



Набор 3: Выброс искажает модель



Набор 4: Одна точка "тянет" модель



Одинаковые числа $\neq$ одинаковая структура!

Только визуализация позволяет увидеть реальную картину

Типы данных и шкалы измерений

Категории задач EDA

Тип задачи	Данные	Техники
Унарный	Y	4-график, вероятностный график
Контроль	Y	Контрольные карты
Сравнительный	Y + факторы	Блочный график, диаграмма рассеяния, ящик с усами
Скрининг	Y + много X	Блочный график, бигистограмма
Оптимизация	Y + много X	Контурный график, МНК
Регрессия	Y + непрерывные X	Диаграмма рассеяния, б-график
Временные ряды	Y_t	Автокорреляция, спектральный график
Многомерный	$X_1, \dots, X_k$	Звездный график, матрица рассеяния

- **4-график** Проверка случайности, распределения, положения и вариации
- **Вероятностный график** Проверка соответствия данных теоретическому распределению
- **ППКК-график** Подбор параметра формы распределения по корреляции
- **Контрольные карты** Мониторинг стабильности процесса во времени
- **Блочный график** Оценка эффекта фактора по всем комбинациям условий
- **Диаграмма рассеяния** Визуализация связи между двумя переменными
- **Ящик с усами** Сравнение распределений по медиане и разбросу
- **Бигистограмма** Сравнение двух распределений по форме, центру и разбросу
- **Контурный график** Поиск оптимальных настроек факторов
- **МНК** Метод наименьших квадратов для подбора модели
- **6-график** Проверка качества регрессионной модели
- **Автокорреляция** Зависимость между соседними наблюдениями во времени
- **Спектральный график** Выявление периодических компонент в данных
- **Звездный график** Визуализация многомерных наблюдений
- **Матрица рассеяния** Парный анализ всех переменных

Типы переменных

Тип	Описание	Примеры
Непрерывные	Значения на интервале	Температура, вес, рост
Дискретные	Только целые значения	Количество детей, число посещений
Категориальные		
Номинальные	Нет порядка	Цвет, страна, пол
Порядковые	Есть порядок	Уровень образования

Тип переменной определяет выбор методов анализа, визуализации и предобработки

Национальное исследование роста семей

- Проводится CDC (Центры по контролю заболеваний США) с 1973 года
- **Кросс-секционное исследование** — «снимок» популяции в определённый момент
- Целевая популяция: женщины и мужчины 15–44 лет
- Сбор данных о семье, браке, беременности, репродуктивном здоровье

Ключевые переменные

- `caseid` — идентификатор (категориальная, номинальная)
- `prglngth` — продолжительность беременности в неделях (количественная, дискретная)
- `outcome` — исход беременности (категориальная)
- `birthord` — порядок рождения (количественная, дискретная)
- `birthwgt_lb/oz` — вес при рождении (количественная)
- `agepreg` — возраст матери (количественная, непрерывная)
- `finalwgt` — статистический вес (количественная)

Базовые предположения измерительного процесса

Четыре фундаментальных предположения

Данные должны «вести себя» как:

1. **Случайные извлечения (Random drawings)**
 - Наблюдения независимы друг от друга
 - Самое важное и наименее проверяемое предположение
2. **Фиксированное распределение (Fixed distribution)**
 - Форма распределения не меняется со временем
3. **Фиксированное положение (Fixed location)**
 - Среднее значение постоянно
 - Нет тренда или дрейфа
4. **Фиксированная вариация (Fixed variation)**
 - Разброс данных постоянен
 - Нет увеличения/уменьшения разброса

Почему проверка предположений критически важна?

Предсказуемость

Если все предположения выполняются:

- Процесс в **статистическом контроле**
- Процесс **предсказуем**
- Можно делать вероятностные утверждения о будущем

Валидность выводов

Если предположения нарушены:

- Процесс **непредсказуем**
- Оценки среднего и разброса бессмысленны
- Выводы могут быть вводящими в заблуждение

Эти предположения относятся к **ошибкам модели!**

Последствия

- Все стандартные тесты становятся невалидными
- Неопределенности становятся бессмысленными
- Эффективный размер выборки меньше номинального
- Простая модель $Y = \text{constant} + \text{error}$ невалидна

Особый случай: автокорреляция

Значение Y_t зависит от Y_{t-1}

- Меньше информации, чем кажется
- Могут быть необнаруженные выбросы

Нарушение фиксированного положения и вариации

Нарушение положения

Среднее дрейфует со временем

- Оценка среднего бессмысленна
- Выбор оценки положения может быть неоптимальным
- Ошибка среднего занижена

Нарушение вариации




Стандартное отклонение меняется

- Оценка стандартного отклонения бессмысленна
- Оценка может быть смещенной
- Доверительные интервалы невалидны

Нарушение распределения

- Влияет на выбор оценки положения
- Для Коши: среднее = 3.70, медиана = -0.016
- Для экспоненциального: среднее = 1.001, медиана = 0.684

Техники проверки предположений: 4-Plot



Интерпретация

- **Run Sequence Plot:** Положение и вариация постоянны
- **Lag Plot:** Данные случайны (нет структуры)
- **Histogram:** Распределение нормальное
- **Normal Probability Plot:** Точки на прямой

Описательная статистика

Среднее арифметическое (Mean)

$$\bar{Y} = \frac{1}{N} \sum_{i=1}^N Y_i$$

- Оптимально для **симметричных** распределений
- Чувствительно к выбросам
- Минимизирует среднеквадратичную ошибку

Медиана (Median)

$$\text{Median} = \begin{cases} Y_{(N+1)/2}, & N \text{ нечетное} \\ \frac{Y_{(N/2)} + Y_{(N/2)+1}}{2}, & N \text{ четное} \end{cases}$$

- Устойчива к выбросам
- Лучшая для **асимметричных** распределений
- Минимизирует среднее абсолютное отклонение

Выбор меры центральной тенденции

Тип распределения	Лучшая мера	Интерпретация
Нормальное	Среднее	Симметричное распределение → все меры совпадают
Равномерное	Полусумма	Короткие хвосты → полусумма даёт наиболее точную оценку
Асимметричное	Медиана	Выбросы смещают среднее, медиана устойчива
Тяжелохвостое	Медиана	Среднее становится бессмысленным из-за экстремальных значений

Мода (Mode)

Наиболее часто встречающееся значение. Используется для определения одномодальности или бимодальности распределения.

Дисперсия (Variance) — s^2

$$s^2 = \frac{1}{N-1} \sum_{i=1}^N (Y_i - \bar{Y})^2$$

Что характеризует: средний квадрат отклонений от среднего.

- **Сильно чувствительна к выбросам** — одно экстремальное значение может резко увеличить дисперсию
- Является несмещённой оценкой генеральной дисперсии (деление на $N - 1$)
- Имеет квадрат единиц измерения (например, кг^2) — сложно интерпретировать
- Оптимальна для нормального распределения

Стандартное отклонение (Standard Deviation) — s

$$s = \sqrt{s^2}$$

Что характеризует: среднее отклонение от среднего в исходных единицах.

- Восстанавливает единицы измерения (например, кг, недели)
- Менее чувствительно к выбросам, чем дисперсия (корень частично компенсирует возведение в квадрат)
- Для нормального распределения: $\approx 68\%$ данных в $[\bar{Y} - s, \bar{Y} + s]$

Интерквартильный размах (IQR)

$$IQR = Q_3 - Q_1$$

где Q_1 — 25-й процентиль (нижний квартиль), Q_3 — 75-й процентиль (верхний квартиль).

Что характеризует: размах центральных 50% данных.

- Робастная мера — не чувствительна к выбросам
- Используется в Box Plot для определения границ «усов»:

Нижняя граница = $Q_1 - 1.5 \cdot IQR$, Верхняя граница = $Q_3 + 1.5 \cdot IQR$

- Точки за пределами границ считаются выбросами

Другие робастные меры разброса

- Размах (Range): $Y_{\max} - Y_{\min}$ — прост, но сильно зависит от выбросов
- Среднее абсолютное отклонение (AAD):

$$AAD = \frac{1}{N} \sum_{i=1}^N |Y_i - \bar{Y}|$$

— менее чувствительна к выбросам, чем СКО

- Медианное абсолютное отклонение (MAD):

$$MAD = \text{median}(|Y_i - \text{median}(Y)|)$$

— наиболее устойчивая к выбросам мера

Гистограммы

Определение

Графическое представление распределения данных, где диапазон разбивается на k интервалов (bins)

$$h_j = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(x_i \in I_j)$$

- h_j — высота (частота) j -го интервала
- $\mathbf{1}(x_i \in I_j)$ — индикатор: 1, если точка попала в интервал, иначе 0
- Сумма всех h_j равна 1 (нормированная гистограмма)
- При увеличении числа интервалов k гистограмма становится более детальной, но шумной

Правила выбора числа интервалов

1. Правило Стёрджеса: $k = \lceil \log_2 n + 1 \rceil$

- Основано на биномиальном распределении
- Хорошо работает для $n \approx 100$ –200, для больших выборок даёт слишком мало интервалов

2. Правило Скотта: $h = \frac{3.5\sigma}{n^{1/3}}$

- Оптимально для нормальных данных (минимизирует среднеквадратичную ошибку)
- Чувствительно к выбросам (использует стандартное отклонение)

3. Правило Фридмана-Диакониса: $h = \frac{2 \cdot IQR}{n^{1/3}}$

- Робастное — использует IQR вместо стандартного отклонения
- Рекомендуются для реальных данных с возможными выбросами
- Минимизирует интегральную среднеквадратичную ошибку

Нормальное распределение

- Колоколообразная форма
- Симметричное
- Умеренные хвосты

Короткие хвосты

- «Обрезанный» вид
- Хвосты обрываются резко
- Midrange — оптимальная оценка


Длинные хвосты

- Тяжелые хвосты
- Точки далеко от центра
- Медиана — лучшая оценка

Бимодальное

- Два ярких пика
- Смесь двух распределений
- Может указывать на синусоидальность

Гистограмма веса при рождении (NSFG)



- Мода (наиболее частое значение) — 7 фунтов
- Приблизительно колоколообразное
- Асимметричное — хвост длиннее влево

Ящик с усами (Box Plot)


Box Plot: структура



Правило выбросов

Выброс: точка за пределами $[Q_1 - 1.5 \cdot IQR, Q_3 + 1.5 \cdot IQR]$

Сравнение распределений с помощью Box Plot



- Медианы: Группа 1 (5) = Группа 3 (5) < Группа 2 (6) = Группа 4 (6)
- Разброс (IQR): Группа 3 имеет наибольший разброс (IQR = 4), Группа 4 — наименьший (IQR = 2)
- Выбросы: только в Группе 1 (2, 8) и Группе 3 (1, 9)
- Симметричность: все группы симметричны (медиана по центру ящика)

Кумулятивные функции распределения (CDF)

Определение

Функция распределения (ФР):

$$F(x) = P(X \leq x)$$


Свойства

1. $0 \leq F(x) \leq 1$ для всех x
2. $F(x)$ — неубывающая функция
3. $\lim_{x \rightarrow -\infty} F(x) = 0$
4. $\lim_{x \rightarrow +\infty} F(x) = 1$
5. $P(a < X \leq b) = F(b) - F(a)$

Преимущества ФР перед ФВ

- Не страдает от шума при большом количестве значений
- Лучше показывает общую структуру распределения

ФР продолжительности беременности



- 10% беременностей заканчиваются до 36 недель
- Первенцы рождаются немного раньше
- Стохастическое доминирование: ФР первенцев выше

Определения

- **Процентиль:** значение, ниже которого находится заданный процент данных

$$p\text{-й процентиль} = F^{-1}(p/100)$$

- **Квантиль:** обобщение процентиля

$$Q(p) = F^{-1}(p), \quad p \in [0, 1]$$

Важные квантили

- Медиана: $Q(0.5)$
- Нижний квартиль: $Q(0.25)$
- Верхний квартиль: $Q(0.75)$
- Децили: $Q(0.1), Q(0.2), \dots, Q(0.9)$

Если ФР одной группы всегда выше другой: первая группа имеет систематически меньшие значения (например: первенцы рождаются раньше)

Функции плотности вероятности (ФПВ) и ядерной плотности

Определение

Функция плотности вероятности (ФПВ):

$$f(x) = \frac{d}{dx} F(x)$$

Свойства

1. $f(x) \geq 0$ для всех x
2. $\int_{-\infty}^{\infty} f(x) dx = 1$
3. $P(a \leq X \leq b) = \int_a^b f(x) dx$

Важное отличие

- **ФВ:** вероятность в точке
- **ФПВ:** плотность вероятности (вероятность на интервале)

ФПВ нормального распределения

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$


Свойства

- Симметрично относительно μ
- Мода = Медиана = μ
- Точки перегиба при $x = \mu \pm \sigma$

Правило 68-95-99.7

- 68% данных в $[\mu - \sigma, \mu + \sigma]$
- 95% данных в $[\mu - 2\sigma, \mu + 2\sigma]$
- 99.7% данных в $[\mu - 3\sigma, \mu + 3\sigma]$

ФПВ нормального распределения



- μ определяет положение центра
- σ определяет ширину (разброс)
- Площадь под каждой кривой = 1

Определение

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

Ключевые компоненты

- K — ядро (обычно гауссовское), h — ширина окна (bandwidth)

Популярные ядра

- Гауссовское: $K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}$
- Епанечникова: $K(u) = \frac{3}{4}(1 - u^2)$ при $|u| \leq 1$
- Треугольное: $K(u) = 1 - |u|$ при $|u| \leq 1$

Выбор ширины окна

- **Маленькое h :** шум, переобучение
- **Большое h :** чрезмерное сглаживание
- Правило Сильвермана: $h = 1.06\sigma n^{-1/5}$

Анализ взаимосвязей

Диаграммы рассеяния

Простыми словами: это точечный график, где каждая точка — один случай. По горизонтали — одна характеристика, по вертикали — другая. Смотрим: есть ли закономерность?

Что мешает разглядеть закономерность — и что делать

Проблема	Решение
Много точек на одном месте	Сделать точки <i>полупрозрачными</i> — где темнее, там больше данных
Числа округлены (целые годы, см)	Чуть-чуть <i>подвигать</i> точки случайным образом — они перестанут слипаться
Данных так много, что ничего не видно	Разбить плоскость на <i>шестиугольники</i> и закрасить их по плотности
Одно-два значения сильно выбиваются	Использовать <i>логарифмическую шкалу</i> — огромные числа станут поменьше


Диаграммы рассеяния

Что мы пытаемся увидеть

Картинка на графике	Что это значит
Точки ползут вверх	Чем больше одно, тем больше другое (рост и вес)
Точки ползут вниз	Чем больше одно, тем меньше другое (скорость и время в пути)
Беспорядочное облако	Связи нет (цвет волос и рост)
Одна точка далеко от всех	Выброс — возможно, ошибка или особый случай

Самое главное: даже если график показывает красивую линию вверх — это не доказательство причины. Это только повод задуматься: «А что тут на самом деле происходит?»

Диаграмма рассеяния: рост и вес



- Положительная корреляция между ростом и весом
- Линейная модель: $\text{Вес} \approx 0.7 \times \text{Рост} - 45$
- Разброс увеличивается с ростом

Ковариация

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Корреляция Пирсона

$$\rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$


- $-1 \leq \rho \leq 1$
- Инвариантна к линейным преобразованиям
- Измеряет только **линейную** связь

Корреляция Спирмена

Использует ранги вместо значений

$$\rho_S = \frac{\text{Cov}(R(X), R(Y))}{\sigma_{R(X)} \sigma_{R(Y)}}$$

Типы корреляции



- Синяя: положительная корреляция
- Оранжевая: нулевая корреляция
- Зеленая: отрицательная корреляция

Важное предостережение

Корреляция не означает причинность!

Возможные объяснения корреляции

1. А вызывает В (прямая причинно-следственная связь)
2. В вызывает А (обратная связь)
3. Скрытая переменная С вызывает и А, и В
4. Случайность (ложная корреляция)

Методы установления причинности

- Рандомизированные контролируемые испытания
- Естественные эксперименты
- Временные ряды (причина предшествует следствию)
- Инструментальные переменные

Практический EDA

1. Импорт и очистка данных

- Загрузка данных из различных источников
- Обработка пропусков (NA, NaN)
- Преобразование типов данных
- Создание новых переменных

2. Исследование одной переменной

1. Построить гистограмму
2. Проверить выбросы
3. Вычислить сводные статистики
4. Построить ФР

3. Парные исследования

1. Построить диаграммы рассеяния
2. Вычислить корреляции (Пирсона и Спирмена)
3. Построить линейные модели

4. Многомерный анализ

- Множественная регрессия
- Учет контрольных переменных

5. Оценка и проверка гипотез

1. Насколько велик эффект? (размер эффекта)
2. Какова вариабельность? (стандартная ошибка)
3. Может ли эффект быть случайным? (p-значение)

Ключевые принципы EDA

«Графические методы — это не просто инструменты, которые можно использовать в EDA.

Это инструменты, которые необходимо использовать для получения инсайта».

«EDA — это подход, который использует данные для выбора модели, а не наоборот».

Что нужно помнить

- Всегда начинайте с визуализации
- Проверяйте предположения перед моделированием
- Используйте несколько графиков для разных аспектов данных
- Не забывайте про выбросы — они могут быть важны
- Корреляция $\neq$ причинность

- **Tukey J. W.** *Exploratory Data Analysis*. — Addison-Wesley, 1977. — 688 с.
- **Downey A. B.** *Think Stats: Exploratory Data Analysis*. — O'Reilly, 2014. — 206 с.